

# 实验报告 / Experiment Report — Evolving Quant Agent (QEA) v0

日期 / Date: 2026-06-09 · 项目 / Project: Evolving Quant Agent v0 · 仓库 / Repo: [github.com/Wrigggy/evolving-quant-agent](https://github.com/Wrigggy/evolving-quant-agent)

一句话 / TL;DR: v0 的机制成立、但还没证出 quant 上的"价值"。离线 mock 下「自动改造 agent 外挂(harness)→ 验证 → 不行就回滚」这套闭环四项信号全亮；接到真实 GDPval 财务任务后闭环能端到端跑通，但没观察到提升 —— 主要被软评分噪声卡住，加上 worker 目前只产文本、不产真实文件，故结论 inconclusive。

## 1. 实验过程与结果 / Process & Results


### 目标 / Goal

验证一个机制，不是刷分：复用已跑通的 AHE 「evolve→falsify→rollback」闭环，把它用到 quant/finance 任务上，看这套自动演化 agent 外挂的闭环能否在 quant 域真实工作并带来提升。

### 名词速览（给没看过这个实验的人） / Glossary

- **harness (外挂)**: 模型外面那套可改的东西；这里拆成 7 个 slot: tool / middleware / skill / prompt / validator / memory / router。
- **quant\_agent (worker, 执行器)**: 在当前 harness 下真正去做题、产出"交付物"的 agent。
- **evolve\_agent (演化器)**: 读失败诊断，每轮只改 harness 的一个 slot，试图让 worker 做得更好。
- **verifier (验证器)**: 给交付物打分。**硬 verifier** = 确定性数值核对；**软 judge** = LLM 按 rubric 打分。
- **OOS pass**: 一道题"算通过"。

### 整体流程 / How it runs (end-to-end)



每一轮 iteration (闭环的一圈) :

- ① evaluate 所有任务→分数
- ② diagnose 把失败蒸馏成 root cause
- ③ evolve\_agent 读①②+rejected-edit buffer → 提 1 个 edit(改某 slot)
- ④ 套到 harness 副本→重新 evaluate
- ⑤ falsify: 出 verdict + 过 gate → keep 或 roll
- ⑥ 三层 trace 落盘 + resume.json(可断点续跑)

设计受 4 条"铁律"约束: ①只打 harness 是真瓶颈的任务; ②硬 verifier 入回路(软信号只做迁移评测); ③多次评估去噪;④按子类/职业分别记分、不要单一聚合。复用 AHE 的 verdict 引擎/manifest/三层 observability; 移植 SkillOpt 的 rejected-edit buffer + strict gate + edit budget; **quant 新增** integrity guard = perturbation probe (防硬编码)。代码 ~1956 行 / 13 commits / 17 单测全过。

## 怎么评分 / Scoring (关键, 三套要分清)

- **硬 verifier** (mock + 合成 A 堆): 每题 0 / 0.5 / 1。1=答案对且**通用** (扰动输入仍对, 过 perturbation probe); 0.5=base 对但**硬编码** (过不了 probe); 0=base 就错。题"通过"= 拿到 1。
- **软 judge** (真实 GDPval): 把该题的 rubric\_json 逐条判「满足? 是/否」×该条分值, 得到加权完成度, 再量化到与专家标准 parity 的 {0, 0.5, 1}——0=低于标准 (完成度 <0.5) / 0.5=持平 (0.5—0.8) / 1=达到或超过 (≥0.8, ≈与人工 gold 一样好或更好)。per-occupation 「pass rate」= 这些 {0,0.5,1} 的均值 (即 GDPval 式 **win-rate**, 平局算半分); 单题"通过"= ≥0.5 (持平或更好)。
- **GDPval 官方评分** (仅作对照, 未采用): 人工/GPT-5 把"模型交付物 vs 人工标准答案"做 pairwise 盲评 → 0 / 0.5 / 1 (模型更好 / 平 / 人更好) → win-rate。无公开 API (只有网页表单且实测无法提交), 所以我们用上面对齐其 0/0.5/1 标准的自建 rubric 评分代替。

注: 下方 E1-E4 的软评分数字采于早期连续 rubric ([0,1] 均值, 阈值 0.6); 评分逻辑已改为上述 {0,0.5,1} parity 制, 重跑会以 win-rate 重新表达 (结论方向不变)。

## 任务长什么样 / What the tasks are

- **合成 A 堆** (有确定数值答案, 驱动硬回路): Black-Scholes 期权定价、贷款摊销表、流动比率 (audit metric)、NPV+IRR 估值。每个引用一个真实 GDPval task\_id 标血缘。
- **真实 GDPval finance** (30 题 = 6 类职业 ×5): 真实职业交付物。例: 审计员对一张 Anti-Financial-Crime 指标表做抽样测试、要求交一个含 'Sample Size Calculation' 工作表的 Excel 文件\*; 理财顾问写配置调整建议备忘录; 投资分析师\*写估值备忘。

## 数据 / Data (四组实验)

| #  | 实验                       | 配置        | 结论先行                                                |
|----|--------------------------|-----------|-----------------------------------------------------|
| E1 | Mock 机制验证(离线、硬 verifier) | 脚本化、2-arm | 闭环成立: 四信号全 PASS、17/17 测试、 <b>HEADROOM CONFIRMED</b> |

| #  | 实验                      | 配置                                | 结论先行                                                                               |
|----|-------------------------|-----------------------------------|------------------------------------------------------------------------------------|
| E2 | 合成 A-pile real          | deepseek-v4-pro, 4 iter           | 能力够、无 headroom: seed 4/7, 4 个 edit 全 HARMFUL/INEFFECTIVE→平                         |
| E3 | GDPval-soft (pro)       | pro worker+judge, 30 题, 4 iter    | gate 太严: 2 个 edit 真抬了分(0.618→0.651/0.645) 却被回滚 → 催生 noise-aware gate               |
| E4 | GDPval-soft (flash/pro) | flash worker + pro evolve, 8 iter | 被噪声卡住: seed~0.60, 噪声底 0.0276, 0/8 kept → SOFT HEADROOM NOT OBSERVED (inconclusive) |

E4 各职业通过率 / per-occupation pass rate (两列估计的差距本身就是噪声证据):

| 职业                              | pass rate(6 次平均, 稳) | pass rate(单次) | mean  |
|---------------------------------|---------------------|---------------|-------|
| Personal Financial Advisors     | 100%                | 100%          | ~0.82 |
| Real Estate Brokers             | 86.7%               | 100%          | ~0.78 |
| Financial & Investment Analysts | 66.7%               | 80%           | ~0.62 |
| Financial Managers              | 56.7%               | 40%           | ~0.52 |
| Securities/Commodities Sales    | 43.3%               | 60%           | ~0.51 |
| Accountants and Auditors        | 13.3%               | 0%            | ~0.28 |

## 案例研究 / Case Study

**Case A — 闭环真的在工作 (mock, 可审计)。** 结论: 四个阶段因果连通、回滚正确。证据: iter1 的诊断说 root cause = Hardcoding (6 题过 base 但过不了 probe) → manifest 的 root\_cause 同样写 Hardcoding → workspace 落盘显示 validator slot 新增 integrity\_guard → verdict EFFECTIVE、通过数 0→6 (同一根因贯穿四层 json)。随后 iter2 故意改坏 code\_exec → 全错 → HARMFUL 正确回滚; iter4 重提该坏 edit → 被 rejected-edit buffer 提前拦下。

**Case B — worker 现在交的是"文本"而非真实文件 (real GDPval, 限制所在)。** 结论: worker 不写 .xlsx/.pptx, 只产一段文本, 所以一大类 rubric 分结构性拿不到。证据: 上面那道审计任务要求"交一个含 'Sample Size Calculation' 工作表的 Excel workbook (每条 +2 分)"; 实跑 flash worker 返回的是 type=str 的 4864 字 markdown——它把公式  $n=Z^2p(1-p)/e^2$ 、 $n\approx 68$ 、"A1-A4 放输入、加一列 QoQ Variance"等用文字描述出来, 但没有任何真实文件。而且代码里只把 task.prompt 喂给它、没喂 reference 附件表, 所以它连真实数据都拿不到、只能自己编个例子 (N=500)。→ "是 Excel 文件 / 有名为 X 的 sheet / 用附件数据算出的值"这些条目必挂, 这正是 Accountants/Auditors 仅 ~0—13% 的直接原因 (这类职业最依赖真文件+附件数据)。

**Case C — edit 抬了分却被噪声回滚 (real GDPval, falsification 的核心两难)。** 结论: evolve\_agent 提的 edit 真把聚合分抬了, 却被判成"可能过拟合/副作用"而回滚——这是软信号下 falsification 最棘手的地方。证据(E3): skill:financial\_computation\_skill 把均分 0.618→0.651、middleware:variable\_pay\_middleware →0.645, 但都拿到 verdict MIXED → 回滚、最终 0 kept。

– 回滚的判定理由 (是不是过拟合?): 旧 strict gate 看到该 edit 造成了未预测的 task 掉分

(unattributed regression), 按设计把任何未预测掉分当作潜在的过拟合/副作用伤害 (edit 偏帮了它 声明要修的任务、却伤了别的任务) → 保守回滚。

– 但真因多半是噪声、不是过拟合: 软 judge 每轮重新生成交付物 + 重新打分, 同一 harness 也会有 1–2 个 task 随机掉分。单样本下"随机掉分"和"真过拟合掉分"无法区分, 于是净正的 edit 被误杀。

– 怎么解决: ① noise-aware gate (已实现) ——不再"有掉分就回滚", 改为"聚合分超过噪声底才 keep", 容忍少量随机掉分; ② 对 worker 交付物 k 次采样取中位——让 per-task 分稳定, 真过拟合 (系统性掉分) 就能与噪声 (随机掉分) 区分; ③ 引入 held-out / selection split (v0 暂未做) ——真过拟合会在 held-out 上掉、噪声不会, 这是区分"过拟合 vs 噪声"的正解。E4 已用 ① 但仍 0/8, 说明单靠 noise-aware gate 不够, ② 是下一步头号动作。

---

## 2. 分析 / Analysis (结论先行)

---

- 机制成立、且忠实复现 —— 因为 E1 在干净硬信号下把四条信号全点亮(含可审计因果链), E2–E4 又证明回路能在真实 LLM + 真实 GDPval 上端到端跑通。
- "无 headroom"有两种不同的脸 —— (a) 能力够型(E2): deepseek 把规范的数值题做得很好 (BS 精确、IRR 收敛到  $1e-13$ ), harness 无从发力; (b) 噪声受限型(E3/E4): 软评分每轮重新生成交付物+重打分, 必然抖动, falsification 分不清 edit 真实效果。这把"软信号入回路"的代价实测了出来。
- E3→E4 的演化说明 gate 设计很关键 —— E3 旧 gate 「任何掉分就回滚」误杀了净正 edit; 改成 noise-aware gate(只认超过噪声底的聚合提升)后,E4 又显示单样本基线+软噪声仍盖过 edit 效应(8 个 delta 全在  $\pm 0.0276$  内)。所以"0/8 kept"不等于"evolve 没用",而是"信号分辨率不够"。
- per-occupation 比单一聚合分有用 —— Accountants/Auditors 在两种估计下都垫底(~0–13%)、Advisors/Real-Estate 接近天花板, 原因清楚:前者要求真 Excel+附件计算(worker 都没有), 后者交付物本就偏叙述文本(纯文本恰好够用)。这印证了铁律④。

---

## 3. 问题与困难 (待讨论) / Problems & Open Questions

---

已解决的工程坑 (都已修+commit): sandbox 挡掉 `import math`; IRR 容差套错( $\pm 643\%$  放水); 未归因 regression 混过 EFFECTIVE; 2.4 小时死锁(client 无超时+SOCKS 代理 stall) → 加 90s 超时 + 并发+单任务降级; `--resume` +每轮 checkpoint。

待你拍板的开放问题 (先说要决定什么, 再说背景):

1. 论文 novelty 锚在哪 (研究定位, 最该先想清楚) —— 要决定: 贡献点立在「演化搜索的时间/样本复杂度优化」上, 还是「evolving-agent 框架本身」上, 还是两者组合。背景: 讨论过可从搜索的时间复杂度入手优化 (用更少的 verifier 调用就找到好 edit —— 对应 ROADMAP 的 prioritized/credit-assigned search、multi-fidelity verifier、fitness vs verifier-call-budget 曲线); 但那只是"搜索效率", 真正的差异化仍需要一个 evolving-agent 框架——harness 级演化 + 硬 verifier 落到 quant 非平稳域, 这是现有工作没碰的点。倾向: novelty 锚在「框架」上, 把复杂度优化做成量化支撑实验 (对照 Life-Harness 全迭代 / AHE 文件编辑 baseline)。先定位再补实验。

2. 去噪 vs 成本（头号技术阻塞）—— 要让软回路能定论，得把 eval 噪声压下去；最直接是对 worker 交付物 k 次采样取中位。tradeoff:eval 调用翻 k 倍(flash 便宜, k=3 可接受)。上不上？
  3. 软信号到底值不值得继续 —— GDPval 无硬 verifier、用软 rubric 驱动是主动放松铁律②。继续在软信号上去噪，还是换一个自带硬 verifier 的 family(如 FinRL-Meta 摩擦回测)拿干净闭环？
  4. judge 偏置 —— 现在是 deepseek 自评 rubric(偏宽松、循环偏置)，官方 grader 无 API。要不要换更强/中立的 judge 做校准？
- 

## 4. 下周计划 / Next Week's Plan（按优先级）

---

1. worker 交付物 k-sample 去噪(#1 阻塞)：每个交付物生成 k=3 次取 median，稳住基线，重跑 flash/pro → 拿到能定论的 soft-headroom 判定。
2. 真实文件生成 + 喂 reference 附件：worker 改为写代码产 .xlsx/.pptx；机械/格式条目走确定性硬检查 → 抬升文本下限、部分找回铁律②。
3. 硬 verifier family 对照：接 FinRL-Meta(带摩擦回测、防泄漏) 做一个真硬信号闭环，与软 GDPval 对照,直接量出"软信号拖累了多少"。
4. judge 升级/校准：复现版 pairwise-vs-gold judge 指向更强模型;周期性手动提交官方 grader 做 calibration。

依赖：#1-#4 需联网 + OpenRouter 余额；官方 grader 校准被"无 API"阻塞，只能人工网页提交。