

# 实验报告 / Experiment Report — Evolving Quant Agent (QEA) v0

日期 / Date: 2026-06-09 · 项目 / Project: Evolving Quant Agent v0 · 仓库 / Repo:

`github.com/Wrigggy/evolving-quant-agent` (private)

状态 / Status: v0 机制验证完成 (mock 全绿); real GDPval 实验跑通但结论受噪声限制 (inconclusive)。

## 1. 实验过程与结果 / Process & Results

### 目标 / Goal

在已复现的 AHE `evolve -> falsify -> rollback` 回路之上，把组件层换成 quant 语义，构建一个最小可跑的 evolutionary harness agent v0，打一个 task family (GDPval finance/accounting)。v0 是机制验证，不是性能跑分——成败看「闭环是否真的工作」，而非绝对分数。

### 设计思路 / Build Thinking

继承自 AHE 复现 `[[project_ahe_deepseek_repro]]` 的四条铁律约束整个设计：

- Headroom**: task 必须落在「harness 是真瓶颈」区间 (process-limited, 非 capability-limited)，否则只会重演 70% 平台期。
- 硬 verifier 入回路**: `evolve->falsify->rollback` 只吃确定性硬信号，绝不用 LLM-judge 当主信号 (软 verifier = 「falsification 建在沙上」)。
- task-aware 去噪**: edit 用 k-repeat 评估，看分布不看单次。
- 无单一聚合指标**: per-subtype / per-occupation 记 delta, 「抬一压一」必须可见。

架构: 7-slot harness (5 个继承自 AHE: `tool/middleware/skill/prompt/memory` + 2 个 quant 原生: `validator / router`); **minimal seed** 只填 `tool` (一个 code-execution sandbox), 其余六空——逼每个组件靠实测 delta 挣位置 (归因纯净)。复用 AHE 的 `evaluate_changes` verdict 引擎 (EFFECTIVE/PARTIALLY/MIXED/INEFFECTIVE/HARMFUL)、change-manifest schema、三层 observability; 移植 SkillOpt 三机制 (rejected-edit buffer、strict gate、edit budget)。quant 旗舰组件 = **integrity guard** = **perturbation probe** (扰动输入重算, hardcoded 能过 base 过不了 probe)。

项目结构 / Structure (纯 stdlib core, mock 零依赖; 1956 LOC):

| 模块                   | LOC | 职责                                                                                               |
|----------------------|-----|--------------------------------------------------------------------------------------------------|
| qea/loop.py          | 442 | evolve→falsify→rollback 驱动 + 2-arm ablation + run_gdpval_soft + 并发 eval + resume/checkpoint      |
| qea/tasks.py         | 468 | A-pile (合成数值 + reference 纯函数 + probe) / B-pile / load_gdpval_finance (真 GDPval + rubric_json 解析) |
| qea/verifier.py      | 283 | HardVerifier (数值 + perturbation probe) + SoftJudge (per-criterion rubric 评分) + sandbox           |
| qea/agents.py        | 233 | quant_agent + evolve_agent (scripted mock / real LLM) + diagnose (ADB-lite)                      |
| qea/falsify.py       | 169 | verdict 引擎 (搬 evaluate_changes) + diff + strict gate + noise-aware gate + rejected-edit buffer   |
| qea/harness.py       | 144 | 7-slot Harness、minimal seed、clone/apply/rollback、to_state/from_state                             |
| qea/llm.py           | 82  | OpenRouter client (provider pin + 超时 + 退避重试) + MockLLM                                           |
| qea/observability.py | 63  | 三层 trace/score/manifest 落盘                                                                       |
| qea/manifest.py      | 61  | change-manifest (HARNESS.md v1.0 schema)                                                         |

入口 run.py ( --mock / --real [ --resume ] [ --core ] ), 测试 tests/test\_smoke.py (17/17 通过)。开发跨 13 个 commit ( 6639359 → 063a18b )。

数据与结果 / Data & Results

四组实验，按时间顺序：

| #  | 实验                      | 配置                                                               | headline 结果                                                                                |
|----|-------------------------|------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| E1 | Mock 机制验证               | 离线脚本、硬 verifier、2-arm                                            | 四条验收信号全 PASS；17/17 测试；HEADROOM CONFIRMED (MOCK)                                            |
| E2 | 合成 A-pile real          | deepseek-v4-pro, 7 合成 A + 12 真 B, 4 iter                         | seed 4/7；模型能力充足；4 个 edit 全 HARMFUL/INEFFECTIVE → flat → NOT CONFIRMED                      |
| E3 | GDPval-soft (pro)       | pro worker+judge, 30 真 GDPval, 4 iter                            | seed mean 0.618 (19/30≥0.6)；2 个 edit 抬升聚合 (0.651/0.645) 却被旧 strict gate 回滚                 |
| E4 | GDPval-soft (flash/pro) | flash worker + pro evolve + pro judge, 30 真, 8 iter (6+resume 2) | seed ~0.60, noise floor 0.0276, 0/8 kept → SOFT HEADROOM NOT OBSERVED (噪声限制, inconclusive) |

E1 mock 2-arm: Arm1 (A-only) OOS 轨迹 0→6→6→6→6；Arm2 (A+B 软信号进回路) 0→9→9→9→9，eval-signal 方差 0.0 vs 0.00031 (干净复现「软信号进回路更吵」)。四信号：①因果连通 ②OOS 单调上升 ③正确 rollback (HARMFUL+INEFFECTIVE+buffer-blocked) ④capability-wall 永不修。

E4 per-occupation pass rate (关键数据, 两种估计——其差距本身就是噪声证据):

| 职业 / occupation                   | pass rate (6-eval 平均, 稳) | pass rate (最终单样本) | mean rubric |
|-----------------------------------|--------------------------|-------------------|-------------|
| Personal Financial Advisors       | 100%                     | 100%              | 0.82        |
| Real Estate Brokers               | 86.7%                    | 100%              | 0.76–0.82   |
| Financial and Investment Analysts | 66.7%                    | 80%               | 0.60–0.65   |
| Financial Managers                | 56.7%                    | 40%               | 0.49–0.56   |
| Securities/Commodities Sales      | 43.3%                    | 60%               | 0.49–0.53   |
| Accountants and Auditors          | 13.3%                    | 0%                | 0.25–0.31   |

案例研究 / Case Study

Case A — 闭环确实在工作 (mock, 6/6 审计级)。iter1: diagnose 给出 root cause tag `Hardcoding` ("6 个 A-task 过 base 但 fail perturbation probe") → `change_manifest` 的 `root_cause` 同样写 `Hardcoding` → `workspace` 落盘显示 `validator slot` 新增 `integrity_guard` → verdict `EFFECTIVE`、OOS 0→6。同一 root cause 贯穿 EVAL→DIAGNOSE→WORKSPACE→VERDICT 四层 (落在 `results/.../iteration_001/{diagnosis,change_manifest,workspace}.json`)。紧接着 iter2 把 `tool:code_exec` 改坏 → 全 task error → verdict `HARMFUL` → 正确 rollback; iter4 重提 iter2 的 edit → 被 `rejected-edit buffer` 在评估前拦下。这正是 §5.4 三条机制信号的直接证据。real 模式也佐证: E2 里真实 `evolve_agent` (deepseek) 自己诊断出了 `sandbox` 的 `import bug`, 并尝试加一个 `import_restorer` middleware 去修 (虽判 `HARMFUL` 回滚) ——说明回路真的在读 eval+诊断并据此行动, 而非空转。

Case B — 闭环在哪里卡住 (real GDPval, §2/3 的核心)。E3 里 `evolve_agent` 提的两个 edit (`skill:financial_computation_skill`、`middleware:variable_pay_middleware`) 真的把聚合分抬了 (0.618→0.651、→0.645, oos 19→22/21) ——但都被回滚。原因: 旧 strict gate 「只要有未预测的 task 掉分就判 MIXED」, 而软 rubric judge 每次评测都重新生成交付物+重新打分, 必然产生 1–2 个随机掉分 → 净正的 edit 被误杀。这把铁律 2 的代价具体化了。据此加了 `noise-aware gate` (只 credit 超过噪声底的聚合提升); E4 进一步显示: 即使有 `noise-aware gate`, `single-sample incumbent` + 软噪声仍盖过 edit 效应 (8 个 edit 的 delta 全在 ±0.0276 噪声带内, 0/8 kept)。

2. 分析 / Analysis

- 机制是真的、且忠实复现。E1 在硬 verifier 下让四条信号全部点亮 (含可审计的 Case-A 因果链), E2–E4 证明回路能在真实 LLM + 真实 GDPval 数据上端到端跑通。  
falsification/rollback/buffer 全程按预期工作。

- 「无 headroom」出现了两种不同性质的形态：(a) 能力充足型 (E2 合成 A-pile) —— deepseek-v4-pro 把 well-specified 数值任务做得很好 (BS=10.4506 精确、NPV+IRR 收敛到  $1e-13$ )，harness 无从发力，正是铁律 1；(b) 噪声受限型 (E3/E4 GDPval soft) ——这是铁律 2 的代价被实测出来：软信号下 falsification 分辨不出 edit 的真实效果，于是要么误杀净正 edit (E3 strict gate)，要么一个都 credit 不了 (E4 noise-aware gate + 单样本噪声)。
- E2 的初始结论曾被误判：一开始把 3 个失败归因为 "eval 非确定性"，per-task 诊断后发现真因是我自己的 task-authoring bug (supplement task 的 prompt 写「Same contract as A\_opt\_01」，而每次 solve 是独立 LLM 调用、看不到 A\_opt\_01 → 模型幻觉出无关问题 → KeyError/TypeError)。修正后模型其实很强。这条提醒：诊断要落到 per-task 证据，别从聚合轨迹脑补根因。
- flash worker + pro evolve (E4) 是正确的 ablation 设计 (弱执行器有 process-headroom + 强 evolve agent)，但结论 inconclusive ——不是「evolve 没用」，而是软信号噪声 (噪声底 0.0276 与 edit 幅度同量级) + 单样本 incumbent 回归均值，使 gate 无法分辨。
- per-occupation 给出可行动信号：Accountants/Auditors 在两种估计下都是明显短板 (~0-13%；flash 在会计/审计这类数值+格式重任务最弱)，Advisors/Real-Estate 接近天花板。这比单一聚合分有用得多 (铁律 4 的价值)。

---

### 3. 问题与困难 (待讨论) / Problems & Open Questions

---

已解决的工程坑 (均已 commit)：

- safe\_exec\_solve 白名单挡掉 import math → 全 ImportError (28c3fed 加白名单 import)。
- IRR 容差 bug: tol=1.0 套到无量纲 IRR ( $\pm 643\%$  放水) → 改 per-metric tol；未归因 regression 能混过 EFFECTIVE → 统一降级 + 收紧 gate；edit signature 120 字符截断碰撞 → hash 全文。
- 2.4 小时死锁：OpenAI client 无请求超时，经 SOCKS 代理的连接 stall 后永久阻塞 (重试只在抛异常时触发) → 加 timeout=90s + max\_retries=0 + 并发 eval + 单任务失败降级 (836a277)。
- SOCKS 代理需 socksio；--resume + 每轮 checkpoint (resume.json) 让中断可续跑 (fa489ba)。

待讨论的开放问题 (想听你意见)：

1. 去噪 vs 成本 (THE blocker)：软回路要可定论，必须把 eval 噪声压下去——最直接是对 worker 交付物 k 次采样取中位 (让 incumbent/candidate 均分稳定)。tradeoff: flash worker 便宜，k=3 成本可控，但 eval 调用翻 3 倍。要不要上？
2. 软信号到底值不值得继续：原始 GDPval 无硬 verifier，用软 rubric 驱动回路是主动放松铁律 2。是继续在软信号上做去噪，还是换一个自带硬 verifier 的 family (如 FinRL-Meta 带摩擦回测) 来拿干净的 iron-law-2 闭环？
3. 官方 grader 不可用：OpenAI GDPval 官方 grader 是 GPT-5-high pairwise-vs-human-gold，无公开 API (只有网页表单、且实测不可提交)。当前用 deepseek 自评 rubric\_json (偏宽松、循环偏置)。要不要换更强/中立的 judge model 做校准？
4. 文本交付物 = 下限：worker 只产 text，format/layout rubric 条目必挂 → 0.60 是 lower bound。是否优先做 .xlsx/.pptx 真实文件生成 (顺带把 ~37% 客观条目变回确定性硬检查)？

5. **worker/task 配对的 headroom**: flash 偏弱、pro 能力充足——需要一个真正 **process-limited** 的 model+task 配对, evolve 才有发力空间。

---

## 4. 下周计划 / Next Week's Plan

---

1. **worker 交付物 k-sample 去噪** (最高优先, #1 blocker): 每个交付物生成  $k=3$  次取 median, 稳定 incumbent/candidate 均分; 重跑 flash/pro 8-iter, **拿到能定论的 soft-headroom 判定**。预期: 噪声底显著下降, 若 pro 的 edit 有真实效果即可被 credit。
2. **.xlsx/.pptx 真实文件生成 + 格式条目确定性检查**: worker 改为写 `openpyxl / python-pptx` 代码经 sandbox 生成真文件; 机械条目 (文件数/页数/可打开) 走确定性硬检查 → 抬升 0.60 文本下限、部分找回铁律 2。
3. **硬 verifier family 对照**: 接 FinRL-Meta (带摩擦回测、防泄漏 train-test-trade) 做一个**真硬信号**的 evolve 闭环, 与软 GDPval 对照——直接回答「软信号到底拖累了多少」。
4. **judge 升级 / 校准**: 复现版 pairwise-vs-gold judge 指向更强模型 (gpt-5 via OpenRouter), 并周期性手动提交官方 grader 做 calibration。
5. **(ROADMAP) 四个优化方向逐一做 fitness vs verifier-call-budget 曲线** (prioritized harness search / multi-fidelity verifier / risk-seeking pruning / offline+online adaptation), 对照 Life-Harness 全迭代 + AHE 文件编辑 baseline。

依赖 / Blocked-on: #1-#4 需联网 + OpenRouter 余额; 官方 grader 校准被「无 API」阻塞, 只能人工网页提交。