

实验报告 / Experiment Report — QEA 本 session 实验线:重构 → 发现 format basin → file-producing worker (v0.1)

日期/Date: 2026-06-16 · 仓库/Repo: github.com/Wrigggy/evolving-quant-agent · 分支/Branch: main (重构已合)+ qea/xlsx-producing-worker (v0.1) · 模型: quant+evolve deepseek-v4-pro, judge qwen3.7-max (OpenRouter)

名词 / Quick glossary (首次出现先解释一句) :
QEA = 演化一个 quant agent "harness"(外骨骼)的实验框架,机制是 evolve→falsify→rollback。
harness/组件 = worker 的 7 个槽(tool/middleware/skill/prompt/validator/memory/router),evolve_agent 每轮改一个组件。
B-pile = 真实 GDPval 金融/会计开放式 deliverable 任务(~30 个);grader = LLM judge 按 rubric_json 逐条打分,聚合成连续 rubric %;gate = decide_keep_soft (候选平均分超 incumbent 超 noise floor 才 keep)。
observation firewall = 把 rubric ground-truth 只喂给 diagnosis、不漏给 proposer 的设计(防 proposer 抄答案/幻觉失败)。
format basin = proposer 反复只提"格式型"edit、出不来的退化态。

0. 实验线索 / The line (本 session 全貌,出发点串起来)

这一段把本 session 做完的工作连成一条因果线——每一步的"出发点"都是上一步的发现:

[出发点 0] 上一阶段发现(memory: proposer_observation_space):
B-pile 写作任务被喂了 A-pile debugger 语义 → proposer 修"幻觉失败",8/8 harmful、0/7 kept
| → 动机:重做观测 + 决策层
▼

[Step 1 · 工程] 重构 QEA(本 session,已合 main):
grader/evaluator 拆分 · 删 PairwiseJudge → decide_keep_soft(连续 rubric %)
· firewalled B-pile debugger(per-criterion verdicts + answer-free critic → sanitized payload)
· 通用 leakage guard · Benchmark 抽象 · 删 A-pile/ablation(synthetic --mock) · iron law 2 → observation firewall
| → 出发点 1:重构有没有修好"修幻觉失败"?
▼

[Exp 1 · loop_test_2026-06-16] 重构后首个真实 run(10 iters):
✅ keep rate 脱离 0(3/10 kept,headroom OBSERVED 0.609→0.662)→ observation-space 修复落地
⚠️ 但发现 FORMAT BASIN:10/10 edit 全是格式型;Accountants/Auditors 卡在 0.282
| → 出发点 2:为什么 proposer 不出来?
▼

[诊断] 根因 = 进化的是 TEXT 不是 CODE:worker 物理上产不出 rubric 要的 .xlsx 工件
| → 出发点 3:给 worker 加"产 .xlsx"能力(框架 seed,不是 evolve)
▼

[Step 2 · 工程] v0.1 file-producing worker(本 session,16 commits/40 tests):
seed tool:xlsx_writer · subprocess exec_artifact · render 桥接 → grader 能 credit 工件
| → 出发点 4:工件真能产吗?尾部能拉起来吗?
▼

[Exp 2 · xlsx_test_2026-06-16] v0.1 真实 run(3 iters,跑完):
✅ 机制成立:全程产出 17 个真 .xlsx / 8 个任务(含能对平的会计摊销表);seed 分 0.609→0.660(+0.05)
❌ 但单靠"产文件"不够:headroom NOT observed(0.660→0.659 平);Accountants 尾部 0.292 ≈ 没动;3/3 edit 仍全是格式型
| → 下一层 = 内容正确性 + 忠实评分(file-aware grader),非"能产文件"
▼

[下一步] sub-project 3 忠实 grader(.xlsx→图片→多模态 / cell-level 硬验证)成为关键路径;并把这条线接到双 benchmark 路线(\$5)

一句话:重构修好了"proposer 修幻觉失败"(Exp 1 keep 脱离 0)并暴露 format basin;诊断指向"进化只动 text、worker 产不出工件";v0.1 给 worker seed 了 xlsx 能力——Exp 2 证实工件能端到端产出、seed 提分 +0.05,但"能产文件"本身没拉起会计尾部、也没让 proposer 逃出 basin:下一层瓶颈是内容正确 + 忠实评分,正好接到 \$5 的"file-output + 硬验证"路线。

1. 实验过程与结果 / Process & Results

目标 / Goal

本 session 两个实验串成一条线:(Exp 1) 验证刚合入的重构(firewalled B-debugger + decide_keep_soft)是否修好了上一阶段的 proposer-observation 缺陷,并观察下一个瓶颈:(Exp 2) 针对 Exp 1 暴露的 format basin,验证假设——会计尾部上不去是因为 worker 物理上产不出 .xlsx 工件,做法是 v0.1 给 worker seed "产 .xlsx"能力,看 (a) 工件能否端到端产出、(b) 尾部能否拉起、(c) proposer 能否逃出 basin。

方法与过程 / Method & Process

- Step 1 工程(apparatus,已合 main commit 0dd68ad):重构 QEA——grader/evaluator 拆分、删 PairwiseJudge → decide_keep_soft、firewalled B-pile debugger(per-criterion rubric verdicts + answer-free critic → sanitized payload,proposer 拿不到答案)、leakage guard、Benchmark 抽象、删 A-pile/ablation(synthetic --mock)、iron law 2 → observation firewall。动机:修上一阶段 proposer_observation_space 缺陷(A-pile debugger 语义喂 B-pile 写作任务 → 修幻觉失败,旧 run 0/7 kept)。

- 两次真实 run 对照,同模型(quant + evolve = `deepseek-v4-pro` ,judge = `qwen3.7-max` ,均经 OpenRouter),同 30 个 GDPval finance 任务,同 `gate decide_keep_soft` :
- Exp 1 — `loop_test` (无 `xlsx`,= 重构验证 + 发现): `results/loop_test_2026-06-16/` ,10 iters,跑完。它不是单纯 **baseline**——是重构后的首个真实 run,既验证 B-debugger 修复,又暴露 `format basin`。
- Exp 2 — `xlsx_test` (有 `xlsx`,v0.1): `results/xlsx_test_2026-06-16/` ,3 iters(iter 1 已完成 + 10 工件;iters 2-3 正 resume,本报告时点未完)。
- Step 2 工程 = v0.1 实现(16 commits,6 个 TDD task,40 tests green;spec/plan 见 `docs/superpowers/specs|plans/2026-06-16-xlsx-producing-worker*`):
- `qea/sandbox.py::exec_artifact` —— `subprocess` 沙箱(`python script.py` 跑在一次性 `temp work_dir`,scrubbed env 抹掉密钥,超时杀进程;借鉴 AHE `LocalSandbox` 的纯 `stdlib` 切片)。
- `qea/artifacts.py` —— `extract_openpyxl_code` (从 worker LLM 输出里抓 `openpyxl` 代码块)+ `render_xlsx` (把产出的 `.xlsx` 渲染成忠实文本: 文件名 + sheet + 单元格值 + 公式串)+ `assemble_artifact_deliverable` (extract→exec→落盘→render,永不抛异常)。
- seed 新增 `tool:xlsx_writer` ;real B worker 检测到该 tool 就在 prompt 里告知"可产 `workbook`",并把产出走渲染管道。
`EvalSummary.deliverables` 仍是 `str` (narrative + 渲染文本),所以 `grader` / 防火墙 / `leakage-guard` 全不动。
- 关键设计点: `openpyxl` 写出的公式没有计算值,故 v0.1 只渲染公式串 + 字面值,不算公式结果(留给 `sub-project 3`)。

数据与结果 / Data & Results

三条结论:(1) Exp 1 —— 重构修复落地:keep rate 脱离 0(3/10,headroom OBSERVED),对比旧 run 的 0/7。(2) Exp 2 —— `xlsx` 机制成立:v0.1 真实模型下端到端跑通,全程产出 17 个真 `.xlsx`;seed 分 +0.05(`artifact criteria` 现在可 credit)。(3) 但 —— "能产文件"本身不够:Exp 2 headroom NOT observed(0.660→0.659 平),`Accountants` 尾部 0.292 ≈ 没动,3/3 edit 仍全格式型。 对照数据:

指标	Exp 1: <code>loop_test</code> 无 <code>xlsx</code> (10 iters)	Exp 2: <code>xlsx_test</code> 有 <code>xlsx</code> (3 iters,完整)
seed mean rubric %	0.6088	0.6604(+0.052,= <code>xlsx</code> 能力效应)
工件产出 (.xlsx / 任务)	0	17 / 8
已 keep edit	3/10(脱离 0;旧 run 0/7)	1/3
轨迹 <code>ms_traj</code>	0.609 → 0.662	0.660 → 0.659 (平,headroom NOT observed)
<code>Accountants/Auditors</code> mean	0.282	0.292(≈ 没动, <code>xlsx</code> 墙仍在)
proposer edit 是否逃 <code>basin</code>	否(10/10 格式型)	否(3/3 仍格式型: <code>format_specialist</code> / <code>structured_formatter</code> / <code>format_enforcer</code>)
noise floor	0.0237	0.010(cache 把同-incumbent 噪声压成 <code>judge-only</code> → floor 触底)

per-occupation 对照(两 run 终态,incumbent 不同,仅指示): `Accountants` 0.282→0.292、`Fin Managers` 0.655→0.659、`Analysts` 0.728→0.825、`Advisors` 0.882→0.874、`Real Estate` 0.835→0.787、`Securities` 0.593→0.516。 → seed 的 +0.05 没落在会计尾部(它仍 0.29),而是散在本就有工件任务、且未触底的 `occupation` 上;会计尾部真正缺的是内容正确 + 能判内容的 `grader`,不只是"有没有 `.xlsx`"。

Exp 1 暴露的 `format basin` (关键发现)—— 10/10 个 edit 全是格式型:

iter	edit	verdict
1	skill:output_format_validator	rollback (MIXED)
2	prompt:format_instructions	keep
3	prompt:output_schema_instruction	rollback (HARMFUL)
4	skill:output_autoformatter	rollback (MIXED)
5	skill:llm_answer_formatter	keep (PARTIALLY_EFFECTIVE)
6	validator:format_compliance	rollback (MIXED)
7	router:format_reminder	keep
8-10	dynamic_format_schema / formatenforcer / outputsanitizer	rollback (HARMFUL x3)

per-occupation(Exp 1 终态):`Advisors` 0.882 / `Real Estate` 0.835 / `Analysts` 0.728 / `Fin Managers` 0.655 / `Securities` 0.593 / **`Accountants` 0.282(.xlsx 墙)**。

案例研究 / Case Study —— worker 真的产出了一份会计工作簿

任务 `7d7fc9a7...` (`GDPval` prepaid amortization schedule,正是 `Accountants` 尾部)。之前(text-only):worker 只能写文字 → rubric 的"提交为 `.xlsx` 工作簿"类 `criteria` 永远 fail → 0.282。现在(v0.1):worker emit 了 `openpyxl` 代码, `exec_artifact` 跑出真文件 `Aurisic_Prepaid_Schedule.xlsx` , `render_xlsx` 把它渲染进 `deliverable`。渲染节选(真实产出):

```
[ARTIFACT FILE: Aurisic_Prepaid_Schedule.xlsx]
Sheet "...": A11:'Monthly Activity Summary'
  A12:'Month' B12:'Beginning Balance' C12:'Additions' D12:'Amortization Expense' E12:'Ending Balance'
  A13:'January' B13:0 C13:622721.83 D13:103786.97 E13:518934.86
```

A14:'February' B14:518934.86 C14:13830.29 D14:106092.02 E14:426673.13
Sheet "Prepaid Insurance" (18x15): A1:'Aurisis' A2:'Prepaid Insurance (Account #1251)' ...

这是一份多 sheet、能对平的摊销表($0 + 622721.83 - 103786.97 = 518934.86$ ✓)。GDPval 该任务 rubric 的核心就是"Begin + Adds - Amortization = End、variance == 0"——现在 grader 能从渲染文本里 credit "提交了.xlsx / 有这些 sheet 与列"这类结构criteria。这就是机制证据:从"结构上不可能满足"到"产出真工件并被渲染打分"。⚠️ 但注意(§2.4):该任务终态仍 0.292——结构可 credit 了,内容是否正确(抽样规则全覆盖、数值对不对)现有文本 grader 判不了,要等 sub-project 3 的忠实/cell-level grader,这正是 Exp 2 的关键负面结论。

2. 分析 / Analysis

2.1 format basin 的根因 = "进化的是 text,不是 code"

Exp 1 的 10/10 格式型 edit 不是 proposer 笨,是它的 action space 只有文字。看代码就清楚 QEA 到底进化什么:

- Component.content 是 str;evolve_agent 提的 Edit 也只带一个 content 字符串。
- 这些 content 怎么被消费? harness.assemble_system_prompt() 只把 prompt / skill / memory / validator 四个槽的 content 拼进 worker 的 system prompt(纯文本)。tool / middleware / router 槽根本不注入 worker。
- worker 的执行(A-pile 的 safe_exec_solve、B-pile 的一次 llm.complete、现在的 exec_artifact)是固定的框架代码,不在演化面上。

结论:QEA 进化的是 TEXT(prompt 片段),从不进化可执行 code。"tool" 组件只是 inert 文字描述,真实行为硬编码在框架里。所以当 proposer 看到"缺.xlsx",它唯一能做的就是改 prompt 文字(加格式指令)→ 但文字永远把 text 变不成 .xlsx → basin。这是 scaffold(可演化文字)vs substrate(固定代码)的边界。

2.2 为什么 xlsx 必须 seed,而不是等它演化出来

"产.xlsx"是 substrate 能力(要真跑 openpyxl、写文件),不是一段 prompt。proposer 在 scaffold 上工作,够不到 substrate。所以正确做法是框架层 seed 这个能力(v0.1 做的),然后让演化在上面做流程优化(何时用、放哪些 sheet)。这也符合 iron law 1:harness 修流程瓶颈,capability gap 该由框架补。

2.3 横向对比 AHE 的 harness 进化

AHE(/Users/kevinwu/Coding/agenthc-harness-engineering ,QEA 的来源)进化的是真 agentic harness;QEA 是它的极简版:

维度	QEA(本仓库)	AHE(原版)
进化对象	7 槽里的 text prompt 片段(只有 prompt/skill/memory/validator 真进 worker)	真 agent 的文件:code / config / skills / prompts
evolve 动作	写一个 prose 组件(Edit.content: str)	用 multiedit_tool / apply_patch patch 文件
worker	一次 llm.complete → text(+ 固定 exec substrate)	agentic:NexAU sandbox 上的 tool loop(run_code_tool / shell/file/web)
tools	inert 文字描述(code_exec/xlsx_writer 行为框架硬编码)	真可执行工具模块
产工件	无 → (v0.1 才 seed 了 xlsx,经框架 exec_artifact)	有(worker 跑 shell/python 原生产文件)
falsification	evaluate_changes verdict taxonomy + gate + rejected-edit buffer (从 AHE/SkillOpt port)	同源(AHE 是出处)
取舍	干净、便宜、确定性、可归因的机制 check——但进化的是"玩具" harness	真实 agentic harness——但进化起来重、贵、noisy

v0.1 的 xlsx 工作 = 把 AHE substrate 的一个最小切片(exec_artifact ≈ 纯 stdlib 的 LocalSandbox)seed 进 QEA,让 worker 能产真工件——朝 AHE 靠了一步,但是 seed(框架写)而非 evolve(proposer 写)。完整方向("让 evolve_agent 自己造可执行工具")= tool synthesis,记在 Track 2 / future。

2.4 这次 xlsx 数据怎么读(诚实版,Exp 2 已跑完)

三层结论,前两层正面、第三层是关键负面发现:

-  **机制成立(强证据)**:全程产出 17 个真 .xlsx / 8 个任务(会计摊销表、MSCI 相关性矩阵、Roth 转换表、payroll、P&L 等),被 grader 渲染读到。单元测试覆盖不到的集成路径,在真实模型下确实跑通。
 -  **seed 提分(中证据)**:seed mean 0.6088→0.6604(+0.05),方向符合"artifact criteria 现在可 credit"。
 -  **但"能产文件"本身没解决问题(关键负面)**:(a) 演化在上面 headroom NOT observed(0.660→0.659 平,1/3 kept 且那一个 keep 落在跨-resume 重采样噪声里);(b) Accountants 尾部 0.292 ≈ 没动——seed 的 +0.05 散在别的占位,没落在会计墙;(c) proposer 仍困 format basin(3/3 edit 全格式型)。
- 为什么 "产文件" 不够 → 指向下一层:interim grader 是把 .xlsx 渲染成文本喂现有 LLM judge——它能 credit "是 .xlsx / 有 sheet X / 用了公式"这类结构/存在criteria(故 seed 提了 +0.05),但判不了内容是否正确(抽样逻辑对不对、摊销表是否真对平、数值是否准)。会计尾部 rubric 的核心恰恰是内容正确。所以 v0.1 证明了"产文件"这一半,剩下一半是"内容正确 + 能判内容的忠实 grader"(sub-project 3)——这也正是 §5 双 benchmark 路线里"file-output + 硬验证(AFC cell-level verifier)"的动机。同时 proposer 仍只提格式 edit,说明它的观测(critic note / tag)仍被格式主导,需要让 critic surface 内容缺陷而非格式。

3. 问题与困难 (待讨论) / Problems & Open Questions

1. [已解决] **never-raise 纪律**:worker 现写代码会产坏文件/超时/损坏 .xlsx; `exec_artifact` (超时杀进程)+ `assemble_artifact_deliverable` (render/copy 都 guard、temp dir 在 finally 清理)保证任何情况只降级不崩。corrupt-xlsx 有回归测试。
2. [已解决] **安全**:worker 代码跑子进程,env 抹掉 `*_API_KEY/*_TOKEN/OPENROUTER*`,子进程内 assert 验证拿不到 `OPENROUTER_API_KEY`。
3. [关键负面,Exp 2 已证] "**产文件**" ≠ **解决尾部**:v0.1 让 worker 产了 17 个真 .xlsx、seed +0.05,但 Accountants 尾部 0.292 没动、headroom 平、proposer 仍只提格式 edit。**根因**:interim grader 只把 .xlsx 渲染成文本判**结构/存在**,判不了**内容正确**。**讨论点**:这把 **sub-project 3(忠实 file-aware grader / cell-level 硬验证)**从"锦上添花"升级为"**关键路径**"——不上它,file-output 维度拿不到真梯度。
4. [待讨论] **噪声地板触底**:Exp 2 noise floor = 0.010(deliverable cache 把同-incumbent 两次 eval 压成 judge-only 噪声 → floor 撞 `max(0.01,...)` 下限);而跨 `--resume` 重启重采样摆动 ~0.017(iter1 的 keep 就落在里面)。→ **floor 低估了真噪声,部分 keep 是噪声驱动**。**讨论点**:noise floor 应在 worker 也重采样的条件下估,或对 incumbent k-sample。
5. [待讨论] **公式只渲染串、不算值(v0.1 限制)**:"用公式且数值正确"类 criteria judge 只能心算。**讨论点**:并入 sub-project 3 的 LibreOffice 重算 + 多模态,还是 interim 先加 `formulas / pycel` (pip)。
6. [待讨论] **proposer 观测仍格式主导**:即便能产文件,B-debugger 的 critic note / tag 仍让 proposer 只提格式 edit(2 个 run 共 13/13 格式型)。**讨论点**:critic 是否要被迫 **surface 内容缺陷**(抽样逻辑错、未对平)而非格式,才能让 proposer 提实质 edit。
7. [待讨论] **provider 摇摆**:停 OpenRouter 改 DashScope Anthropic 网关失败(token 被拒 401/403 `invalid api-key`,两 header 都试),已 rollback; AnthropicLLM backend 已就位(token 一设自动切)。**讨论点**:长期算力走哪家——代码 provider-无关,换家只改 `.env`。

4. 下周计划 / Next Week's Plan

(Exp 2 已跑完,判定:xlsx 机制成立但"产文件"没解尾部 → 下一步重排序)

1. 【**关键路径**】 **sub-project 3 一 忠实 file-aware grader**(Exp 2 把它从可选升为必做):.xlsx → LibreOffice headless 渲染 → 图片 → 多模态 judge(AHE `read_visual_file` 是参考),顺带公式重算(问题 5);并对 **AFC 类任务先做 cell-level 确定性 verifier**(§5.3.4),让 file-output 维度真正拿到内容梯度。
2. **修噪声地板**:worker k-sample / 跨 resume 用稳态分数,让 floor 反映真噪声(问题 4)——否则 keep 信号不可信。
3. 让 **critic surface 内容缺陷**:改 B-debugger 观测,使 proposer 能提实质 edit 而非 13/13 格式型(问题 6)。
4. **sub-project 2 一 gold-file 获取**:fetch+缓存 GDPval `deliverable_file_urls` 后的人工 gold 文件,为 vs-gold 忠实评分铺路。
5. **双 benchmark 路线启动(§5)**:发起 **FAB private validation 450 的 license 申请**(§5.4 待决第 1 项,组内确认后);搭 baseline harness 做进化种子;GDPval 作 held-out。
6. **Track 2 / provider**:tool synthesis(`exec_artifact` 已是纯 stdlib 前置)按需单开;算力 provider 定盘后改 `.env` 即可。
6. **算力 provider 定盘**(问题 5):给一个有效 key, `.env` 切换即可,无需改代码。

5. 后续路线 / Research Roadmap — 多模态输出 × 双 benchmark 进化

来源:一次技术讨论纪要(2026-06)。⚠ 本节所有 benchmark 数字均来自公开来源、为讨论时点值,正式引用前务必复核最新 **leaderboard / 样本量** (出处见 §5.6)。与本 session 的关系:v0.1 的 file-producing worker 正是这条路线的第一块砖(file-output 能力 + §5.4 的"文件输出 + 硬验证"桥梁)。

目标重定:让 QEA 在 finance 域内,从一个(近)无工具 agent 进化成能覆盖 file-output 与文本 QA 两类任务的 finance agent;但"对着两个 benchmark 一起进化成通用 agent"这一原始表述有结构性问题,需重构(§5.3)。

5.1 核心技术结论:多模态 I/O 的硬约束 → fitness landscape 不连续

- **输出端**:LLM 前向只产 token;xlsx 是 zip 二进制,单次 LLM 调用稳定产不出。产 xlsx 必须有一层"执行/序列化"(谱系:最小 = 模型吐 JSON/代码 + 宿主 `df.to_excel()`;最大 = 带文件系统的 agentic harness)。标准模式恒为 **模型写代码 → 代码产文件**(`openpyxl/pandas`)——这正是 v0.1 `exec_artifact` 做的。
- **输入端(对称)**:xlsx 也非原生输入模态。两条路:(A)预先 `read_excel` → CSV/MD/JSON 文本进 prompt(结构固定时首选);(B)给 `code-exec` 工具让模型自己 `pd.read_excel`。厂商"文件上传"本质是托管版路径 B。
- 对 **QEA 的关键含义**:file-output 任务上,真·无工具 agent 得分硬性 ≈ 0(交不出文件),该**维度梯度是平的**——进化必须在早期跨过"获得 code execution"这道**不连续的坎**。对比文本 QA(FAB)无工具仍能凭记忆给非零答案,**landscape 连续**。两 benchmark 的进化轨迹形状因此显著不同,需分别处理。

5.2 两个 benchmark 对比 (已 web 复核 2026-06;✓ = 已确认,出处见 §5.5)

维度	GDPval(finance 子集)	FAB v2(Vals AI)
输出形态	真实文件 ✓(documents/slides/diagrams/spreadsheets/multimedia)	纯文本答案 + 数字,无文件 ✓
评分	blind pairwise win-rate ✓(官方:专家盲比模型 vs 人类交付;Artificial Analysis 出 GDPval-AA Elo 版)——one-shot/ 主观/慢/贵	dealbreaker 门控加权 partial credit + All-Pass ✓(可程序化硬验证)

维度	GDPval(finance 子集)	FAB v2(Vals AI)
工具/harness	开放、官方 agent harness 未开源;但 OpenAI 开了 evals.openai.com 自动评分服务 ✓	固定六工具 ✓(edgar_search / web_search / parse_html_page / retrieve_information / ca 已开源;每题 2h(纪要,未单独复核)
规模	1320 全集 / 220 gold 开源 ✓;Finance&Insurance gold = 25 题 ✓	927 ✓ = public 27 / private validation 450(可 license ✓)/ test 450;成绩只报 test 防
自动 fitness 信号	无(需自建 grader)	有(但 public 仅 27)
能否进 QEA loop	否(win-rate/Elo 非 hard verifier)	是(注意样本量)
顶格成绩	顶级模型 win-rate vs 人类专家多数仍 <50%,确切区间以 GDPval / GDPval-AA leaderboard 为准(原"47-70%"未精确复核)	partial credit Gemini-3.5-Flash 57.86 / Fable-5 56.31 / Opus-4.8 53.92 ✓;All-Pas

- FAB 九类中 Financial Modeling(如 Ralph Lauren 困境收购 Capri 评估 + DCF)与 Precedents top out 仅 23% ✓(对比:Earnings/General-Quant/General-Qual 70%+、Disclosure/Market 60s)→ Financial Modeling 是最高 headroom 方向。
- GDPval 代表性 xlsx 任务 = 反金融犯罪风险审计(AFC,Accountants & Auditors): Population.xlsx 进 → 按 90% 置信/10% 误差算抽样量、J 列环比方差、按多条件规则在 K 列标记抽样 → 产 Sample.xlsx(两 tab)。xlsx-in/xlsx-out 且抽样逻辑有确定答案 → 可写 cell-level 确定性 verifier(§5.3.4 关键)。

5.3 方案重构(可行性判断)

- 评分形态不兼容 → 一个进 loop,一个 held-out:铁律"hard verifier only in loop"直接排除 GDPval(Elo 主观)。FAB-style 可验证任务进 evolution loop 当 fitness;GDPval 作 held-out 泛化测试,仅结束时评一次。叙事增益:"在可验证任务上进化的 harness 能否迁移到文件输出任务"本身是干净的研究问题。
- fitness 数据量 = 比架构更先决的瓶颈:FAB public 仅 27 → 直接进化必过拟合,test 私有报不了;GDPval 220 无 grader。方向(倾向已定,待组内确认):in-loop fitness 倾向 (a) license FAB private validation 450(已确认该 set 可申请 license);备选 (b) 自建数百~上千道程序化可验证 SEC QA。此决策定下来前,进化算法与 harness 接口都是空中楼阁 → 已列为待办第 1 项申请 license。
- "从零工具进化"的预算风险 → baseline harness 做种子:头 ~80% 提升来自已知 scaffolding(code-exec/EDGAR/calculator);QEA 卖点是 harness 源码进化,越过 table-stakes 才有意义。用合理 baseline harness 做进化种子,把预算投到非显然部分。(与本 session 的"capability 该 seed、process 才 evolve"判断一致。)
- AFC 审计任务 = file-output + 硬验证的桥梁:其抽样量公式/方差列/规则覆盖可写成 cell-level 确定性 verifier,不依赖 Elo。行动:找/造一小批"文件输出 + 可程序化校验"任务,把 file-output 维度纳入 hard-verifier loop,让进化在多模态输出上真正拿到梯度,而非只在纯文本上进化、指望白白迁移。(= 本 session sub-project 2/3 的硬验证版延伸。)
- 成功判据重构:不以绝对 SOTA / "通打"为目标(学生项目难刷榜首)。改为:进化出的 harness vs 强手工 baseline harness 在同 benchmark 上的相对增益,逐 category 拆 delta。覆盖范围初步定为全 9 类(做尽量通用型),但仍逐类报 delta——这样既保通用性,又能把最高 headroom 的 Financial Modeling(及 Precedents)当 headline 子 claim(如"harness 进化把 Financial Modeling pass rate 从 X 提到 Y"),通用性与可发表/可证伪兼得。

5.4 待决 / 已定问题

仍待决(优先级序):

- in-loop fitness 数据(最高优先级):倾向 license FAB private validation 450(已确认可申请),待组内讨论确认;备选自建可验证 SEC QA。决定后续全部设计 → 行动:发起 license 申请。
- 种子 harness:进化起点是真·无工具还是 baseline harness?报告里怎么处理"不连续坎"?(§5.1 / §5.3.3)
- baseline 对照:强手工 harness 的具体配置(算相对增益用)。

已定(本轮讨论拍板):

- GDPval 接入:GDPval 作 held-out win-rate/Elo 一次性评测 + 为 AFC 类"文件输出 + 可硬验证"任务自建 cell-level verifier 子集(§5.3.1 + §5.3.4)。
- category 粒度:初步覆盖全 9 类,做尽量通用型,逐类报 delta,Financial Modeling(+ Precedents)为 headline 子 claim。

5.5 出处(已 web 复核 2026-06)

- GDPval ✓:OpenAI GDPval 论文 [arXiv:2510.04374](#) ;OpenAI 官方页 + 自动评分 evals.openai.com ;Epoch AI;amaarora 复现博客(SmolAgents harness,含 AFC 审计任务 prompt 原文)。已确认:1320 全集 / 220 gold / Finance&Insurance gold 25 题 / 文件型交付 / blind pairwise win-rate。
- FAB v2 ✓:Vals AI 官方页;论文 [arXiv:2508.00828](#) ;GitHub [vals-ai/finance-agent-v2](#) 。已确认:927(27/450/450,test-only 计分)/ 六工具(v1.1 四工具 + calculator + price_history)/ partial-credit 57.86·56.31·53.92 / All-Pass <46% / Financial Modeling & Precedents top out 23% / 九类。
- 仍待复核:GDPval 文件交付占比的精确百分比与 SOTA win-rate 区间;FAB"每题 2h"时限。