


实验报告 / Experiment Report — QEA 自演化 agent: 从 baseline 到泛化 Level-B 演化机制

日期/Date: 2026-06-30 · 实验/Experiment: evolving-quant-agent (QEA) Phases 1-5 两周回顾 · 环境/Env: .venv-nexau (py3.14), worker deepseek-v4-pro, judge qwen3.7-plus k=2, OpenRouter via local SOCKS proxy

0. 背景一句话 / One-line context

我们要造一个自演化的 agent harness: 一个 worker agent 做金融分析任务, 一个 evolve agent 改 worker 的定义文件(prompt / 工具 / 配置)让它做得更好, 中间夹一个确定性的 loop 负责打分、保留/回滚。核心研究问题: 这套演化机制能不能真产生提升, 且能泛化到不同 base harness。



1. 实验过程与结果 / Process & Results

目标 / Goal

两周内回答三件事: (1) worker 基底从 Stirrup 迁到 NexAU 后质量是否保真; (2) 怎么制造 Level-B headroom (削弱 worker 让演化有东西可恢复); (3) 演化机制能否泛化 + 真跑通。

方法与过程 / Method & Process

按 Phase 推进, 每步可量化:

- **Phase 1-3 | substrate 迁移:** worker 从 Stirrup (纯 Python 代码定义的 agent) 迁到 NexAU (agent = 一个目录: agent.yaml + systemprompt.md + tool_descriptions/ + tools/)。
迁移目的: 让“可演化的 harness”本身就是可编辑的文件目录。架构定为一个确定性 loop 编排两个平级 NexAU agent (worker + evolve), 不是 agent 套 agent。
- **Phase 4 | Level-B loop + 两个 weak worker 实验:** 造削弱版 seed worker 制造 headroom, 跑独立多模态 per-rubric 打分, 加了 deliverable-format gate。

- **Phase 5(两周终点) | 把机制泛化 + 跑通:**对照 AHE/ADAS/DGM/AlphaEvolve/AFlow 文献设计, 把 loop 做成 benchmark—无关,采用 AHE 的"预测—证伪"keep/rollback,补齐 evolve agent 到 AHE 形态。

数据与结果 / Data & Results

(a) **Substrate 保真 —— 迁移没掉质量。** GDPval finance ~30 任务,同一套多模态 per-rubric grader:

substrate	worker 形态	graded	mean multimodal	infra errors
Stirrup (code)	E2B sandbox	26/30	0.807	4 (E2B 超时/断连)
NexAU (agent dir)	LocalSandbox	30/30	0.797	0(修了 connect-timeout 后)

迁移后质量持平(−0.010)。FAB v2 public−27 同样持平(Stirrup 0.659 vs NexAU 0.618)。

一个通俗但关键的点:worker 现在能交出"多文件交付物"(xlsx/pdf 等),是因为它有了自己的 **agentic 循环**。Stirrup / NexAU 形态的 worker 能**多轮地**读输入、建文件、存文件、检查;而更早的"code agent"形态**没有自己的循环**——只能一次性吐文本,所以根本产不出文件。正是"给了 worker 一个循环"这件事,把纯文本 baseline 的得分抬了 +0.169(多模态再 +0.020)。这条后面很重要:worker 的能力,很大一部分来自它的循环,而不只是它的 prompt。

(b) **两个 weak worker —— headroom 的关键发现。** 同一套机制,只换削弱方式:

weak seed	削弱方式	weak	full	gap	有 headroom?
GDPval	prompt 砍成一行 + 裸 shell	0.791 / gated 0.771	0.797 / 0.772	~0	❌ 无
FAB	删 4 个 SEC 检索工具绑定,只留 fetch_page+web_search	0.388	0.618	−0.230 (−37%)	✅ 有

核心结论(说人话):想让"演化"有东西可恢复,就得削掉 worker 一轮之内自己补不回来的能力。

– 砍 **prompt**(把指导砍成一行):没用。强 base model 一轮内自己就把套路想起来了 → GDPval ~0 gap。

– 砍 **工具/能力**(删掉 SEC 检索工具):有用。没有检索工具,worker 在一个 episode 里**重建不出**"找到 filing → 深读"的能力 → FAB 留下真 0.23 gap,13/27 任务直接塌成 ~45 字符的非答案。

换句话说:worker 的能力主要长在"工具 + 循环"上,不在 prompt 文字上;所以削弱也要削在工具/循环上。

案例研究 / Case Study

Case A — "机制能工作":FAB weak 上 evolve agent 做出设计中的恢复编辑(Phase 5,本 session 实测)。

weak FAB worker 缺检索工具,fab_00/fab_08 因够不着 SEC filing 塌成非答案。把 firewall-off 证据语料

(答案无关:失败 rubric 条目 + 进程观察 + worker 自己的产出,不含 gold)喂给 evolve agent 后,它:

- 正确诊断 `MissingRetrievalCapability`;
- 把目录里实现仍在、但 agent.yaml 未绑定的 `company_filings` + `retrieve_from_filing` re-wire 回去

(实测 diff: +28/-7,改 `agent.yaml` + `systemprompt.md` + 2 个 tool 描述;agent.yaml `tools`: 从 2 个变 4 个);

- 重写 systemprompt 成"发现 filing URL → 深读 → 引用作答"4 步流程;
- 给出正确 prediction `{"predicted_fixes":["fab_00","fab_08"]}`,零答案泄漏。

⚠ 诚实标注:这是简单难度档。削弱时只删了 agent.yaml 绑定,工具的实现和描述文件都留在目录里,我写的 NexAU 参考又点名了"re-wire unbound tool"这个动作 —— 恢复目标被 signpost 了。所以本案证明的是管道通了(诊断→编辑→落地→无泄漏),不是 evolve agent 的能力。

Case B — "机制在哪卡住":三个基础设施坑 + 一个吞吐瓶颈。 端到端不是一次跑通的——evolve agent

推理一直是对的,但执行被三个 NexAU 基础设施坑挡住(都靠探针逐个定位、已修,细节在 commit / checkpoint):

provider 路由导致空响应、work_dir 用了相对路径导致读写全失败(agent 因此幻觉式报告"已编辑"实则没改)、

弱模型拼不对多行 shell 写入(改用结构化文件工具解决)。修完后管道才通。最后卡在吞吐:weak FAB worker

没检索工具时每个任务空转到 `max_iterations:40` (~10–17min/run),加上 noise-floor 重复评 + 串行,

小样本也要 ~80min,所以"分数恢复"这一环还没测到(已暂停,见 checkpoint)。

2. 分析 / Analysis

- "削弱什么"比"削弱多少"重要。prompt-weakening 在强 base model 上是无效削弱(它一轮自恢复),GDPval ~0 gap 就是证据;真正可演化的 headroom 必须来自循环自恢复能力的硬缺口(工具 / 迭代预算)。这把"该在哪个 benchmark 上跑演化"从直觉变成了判据:FAB 是对的,GDPval 不是。
- 早期 5 任务子集的 weak 0.743 > full 0.604 是假信号,full-30 纠正为持平 —— 提醒小样本结论必须全集复核(这次 Phase-5 暂停的 n_tasks=2 同理,只能定性、不能下数值结论)。
- 机制泛化已在代码层兑现: Evaluator 抽象把 benchmark-specific 评分(GDPval 多模式 render vs FAB 文本

score_rubric)藏到接口后, run_levelb(cfg, benchmark) 换 Benchmark+seed 即可跑两个 benchmark,不改 loop。

- **反作弊我们其实超出公开文献。** ADAS/Gödel 无防硬编码机制;DGM 是反面教材(能写代码 + 能看 reward 检测器
→ agent 改代码把检测器致盲)。我们的 firewall(答案无关诊断)+ LeakageGuard 双层,且把 firewall 设为 canonical 默认、ahe_corpus 仅作可切换的 firewall-off 实验档。
- **本质瓶颈与 AHE 一致:evolve-agent 强度。** deepseek 推理方向对(诊断/计划都对),但执行弱(空响应、heredoc、幻觉报成功)。三个 blocker 修完后管道才通 —— 这恰好印证 AHE "evolve-agent 是瓶颈"的结论。

3. 问题与困难 (待讨论) / Problems & Open Questions

- **[核心讨论] 削弱 base harness 该削"工具插件"还是"引擎循环能力"?** 这取决于最终科研目标。我们的目标是保持泛化、把这套演化机制外推到多种 base harness,而这两种削弱方式的泛化属性不同:
- **削工具插件(如 FAB 删 SEC 工具):**headroom 是 **benchmark-specific** 的——只有 FAB 有 SEC 工具, GDPval 没有。当前简单档走的就是这条,好处是恢复路径清晰、deepseek 够得着。
- **削引擎循环能力(如砍掉 tracer / 砍迭代预算 / 砍掉"产出文件的循环"):**headroom 是 **benchmark-无关的**——每个 **agentic worker** 都有循环,这种削弱对 GDPval / FAB 一视同仁地制造 headroom(回到 §1:GDPval worker 能产多文件正是靠循环,砍掉循环它就和早期 code-agent 一样产不出)。这更契合"外推到多 harness"的目标,但要小心别削过头超出 evolve agent 的重建能力(AHE 已证 evolve-agent 是瓶颈)。讨论点:为了泛化,是否应把削弱重心从"工具"移到"引擎循环"?
- **多个 base harness(agent 框架)候选 —— 演化机制要外推到的目标基底,不只是 NexAU:**除当前的 NexAU,候选有 mini-SWE-agent、smolagents、OpenAI Agents SDK、Confucius Code Agent。
诉求:演化机制(loop + evolve agent + firewall + 预测-证伪 keep/rollback)本身**不应绑死 NexAU**,而应能套在任意一个 agent 框架上去演化它的 harness。注意区分两条轴:**框架轴**(NexAU / mini-SWE-agent / ...,即"用什么 agent 基底")与**任务轴**(FAB / GDPval / Terminal-Bench,即"做什么任务")。这条也呼应

上面的削弱之争:跨框架通用的 headroom 更可能来自"引擎循环能力"这类每个框架都有的东西,而非某框架

特有的工具插件 —— 这正是把削弱重心往"引擎循环"移的理由。

- [已解决] 三个 NexAU 基础设施坑(provider-pin / 绝对 work_dir / 结构化文件工具)已修并写入 checkpoint, 属于"基底踩坑"而非机制问题。
- [待讨论] 简单难度档signpost太强。当前 FAB weak 把恢复目标(工具描述文件)留在目录里 + 参考点名了招式, 所以"它会 re-wire"不能解读成能力。讨论点:升难度档的顺序 —— 先删描述文件(逼它推断能力),还是直接删实现逼它写代码?后者很可能 deepseek 直接零增益(能力不足),那是否值得现在做,还是先用简单档拿到 score-recovery baseline 更有价值?
- [待讨论] firewall 成本未量化。 ahe_corpus (firewall-off,不给 gold)vs sanitized (firewall-on) 谁的增益更高、firewall 到底"花"了多少分,需要一次对照。要不要把"让 evolve agent 读 gold"也作为上限消融 (预期增益=硬编码)来夹出区间?
- [待讨论] 吞吐 vs 保真的取舍。把 weak seed max_iterations 40→12 能省 3-4 倍时间,但会改 weak 的绝对分(0.388 是 40 轮下测的)。简单档"看管道是否恢复"用低轮次够吗,还是必须保 40 轮可比?

4. 下周计划 / Next Week's Plan

1. 打三个吞吐补丁 + 跑完简单档完整 loop,拿到 score-recovery baseline。补丁:weak seed max_iterations 40→~12、noise-floor 改固定小 margin(免跑第二遍 seed)、evaluate_dir 加并发。
预期产出: 0.388 → ? 的轨迹 + keep/rollback verdict,首次量化"演化是否真恢复了分数"。
2. 升难度档做干净的能力测试(依赖 1 先拿到 baseline):tier 1 删工具描述文件;tier 2 删实现逼真代码合成;
并软化 NexAU 参考(去掉"re-wire"招式提示)。目的:把"管道通"升级成"evolve agent 能力"的诚实证据。
3. firewall ON/OFF + gold-reading 消融:用 evidence_mode 一键切换,量化 firewall 成本与上限。
4. 合并 Phase-5 分支 worktree-phase5-levelb-mechanism 到 main(当前所有 Phase-5 工作未合并)。

阻塞项 / Blocked:无硬阻塞;计划 1 的吞吐补丁是后续一切跑分的前置。