


实验报告 / Experiment Report — QEA 自演化 agent: 从 baseline 到泛化 Level-B 演化机制

日期/Date: 2026-06-30 · 实验/Experiment: evolving-quant-agent (QEA) Phases 1-5 两周
回顾 · 环境/Env: .venv-nexau (py3.14), worker deepseek-v4-pro, judge qwen3.7-plus
k=2, OpenRouter via local SOCKS proxy

0. 背景一句话 / One-line context

我们要造一个自演化的 **agent harness**: 一个 **worker agent** 做金融分析任务, 一个 **evolve agent** 改 **worker** 的定义文件(prompt / 工具 / 配置)让它做得更好, 中间夹一个确定性的 **loop** 负责打分、保留/回滚。核心研究问题: 这套演化机制能不能真产生提升, 且能泛化到不同 **base harness**。



1. 实验过程与结果 / Process & Results

目标 / Goal

两周内回答三件事:(1) worker 基底从 Stirrup 迁到 NexAU 后质量是否保真;(2) **怎么制造 Level-B headroom**(削弱 worker 让演化有东西可恢复);(3) 演化机制能否泛化 + 真跑通。

方法与过程 / Method & Process

按 Phase 推进,每步可量化:

- **Phase 1–3 | substrate 迁移:** worker 从 **Stirrup**(纯 Python 代码定义的 agent)迁到 **NexAU**(agent = 一个目录: `agent.yaml` + `systemprompt.md` + `tool_descriptions/` + `tools/`)。
迁移目的:让"可演化的 harness"本身就是**可编辑的文件目录**。架构定为一个**确定性 loop 编排两个平级 NexAU agent**(worker + evolve),不是 agent 套 agent。
- **Phase 4 | Level-B loop + 两个 weak worker 实验:**造削弱版 seed worker 制造 headroom,跑独立多模态 per-rubric 打分,加了 deliverable-format gate。

- **Phase 5(两周终点) | 把机制泛化 + 跑通:**对照 AHE/ADAS/DGM/AlphaEvolve/AFlow 文献设计, 把 loop 做成 benchmark–无关,采用 AHE 的"预测–证伪"keep/rollback,补齐 evolve agent 到 AHE 形态。

数据与结果 / Data & Results

(a) **Substrate 保真** —— 迁移没掉质量。 GDPval finance ~30 任务,同一套多模态 per–rubric grader:

substrate	worker 形态	graded	mean multimodal	infra errors
Stirrup (code)	E2B sandbox	26/30	0.807	4 (E2B 超时/断连)
NexAU (agent dir)	LocalSandbox	30/30	0.797	0(修了 connect–timeout 后)

港 fidelity –0.010,统计上持平。 FAB v2 public–27:Stirrup generous 0.659 vs NexAU 0.618(同样持平)。

文件型 worker + reference 文件把纯文本 baseline 的 text–grade 抬了 +0.169,多模态再 +0.020。

(b) **两个 weak worker** —— headroom 的关键发现。 同一套机制,只换削弱方式:

weak seed	削弱方式	weak	full	gap	有 headroom?
GDPval	prompt 砍成一行 + 裸 shell	0.791 / gated 0.771	0.797 / 0.772	~0	❌ 无
FAB	删 4 个 SEC 检索工具绑定,只留 fetch_page+web_search	0.388	0.618	–0.230 (–37%)	✅ 有

核心结论(conclusion–first):headroom 来自"agentic 循环无法在单 episode 内自恢复的能力缺失",不是 prompt 文字。 GDPval 的通用 shell 让强 worker 一轮内自己补回缺失的指导 → 无 gap;FAB 的 SEC

检索工具无法从 fetch_page+web_search 重建 → 留下真 0.23 gap(13/27 任务塌成 ~45 字符的非答案)。

(c) **deliverable–format gate:**输出文件扩展名不匹配 gold(文本–gold 任务豁免)就判 0。两个 worker 各只动 ~–0.02(29/30 输出对类型),证明格式不是当前主要失分点。

案例研究 / Case Study

Case A — "机制能工作":FAB weak 上 evolve agent 做出设计中的恢复编辑(Phase 5,本 session 实测)。

weak FAB worker 缺检索工具,fab_00/fab_08 因够不着 SEC filing 塌成非答案。把 firewall–off 证据语料

(答案无关:失败 rubric 条目 + 进程观察 + worker 自己的产出,不含 gold)喂给 evolve agent 后,它:

- 正确诊断 `MissingRetrievalCapability`;
- 把目录里实现仍在、但 `agent.yaml` 未绑定的 `company_filings` + `retrieve_from_filing` re-wire 回去
(实测 diff: +28/-7, 改 `agent.yaml` + `systemprompt.md` + 2 个 tool 描述; `agent.yaml` `tools:` 从 2 个变 4 个);
- 重写 `systemprompt` 成"发现 filing URL → 深读 → 引用作答"4 步流程;
- 给出正确 prediction `{"predicted_fixes":["fab_00","fab_08"]}`, 零答案泄漏。

⚠ 诚实标注:这是简单难度档。削弱时只删了 `agent.yaml` 绑定,工具的实现和描述文件都留在目录里,
我写的 NexAU 参考又点名了"re-wire unbound tool"这个动作 —— 恢复目标被 signpost 了。
所以本案证明的是
管道通了(诊断→编辑→落地→无泄漏),不是 evolve agent 的能力。

Case B — "机制在哪卡住":三个基础设施 blocker(靠探针逐个定位)+ 一个吞吐瓶颈。

端到端不是一次跑通的,定位链如下(每步有硬证据):

1. **LLM 空响应风暴** → 根因:OpenRouter 把 `deepseek-v4-pro` 路由到 flaky provider 返回 `content_len=0` (小 context 也发生);judge 有 provider pin 而 NexAU agent 没有。修:经 `extra_body.provider` (NexAU `LLMConfig` 无该字段,走 `extra_params` → `to_openai_params`) pin 官方源。
2. **"summary 说改了但 diff 空"** → 根因:`work_dir` 是相对路径,sandbox shell 从别的 cwd 去 `cd <相对路径>` 失败 → 每次 read/edit 都 "File not found" → agent 空转到 `max_iterations` 后幻觉式叙述了一堆没发生的编辑。修:`work_dir` 全部 `.resolve()` 绝对化。(此 bug 真实 loop 也中招。)
3. **deepseek 拼不对多行 heredoc** → 编辑不落地。修:给 evolve agent 配 `read_file / write_file / replace` 结构化工具 —— 这正是 AHE evolve agent 自带文件工具的原因。
4. **吞吐瓶颈(已暂停处)**:weak FAB worker 每个检索任务空转到 `max_iterations:40` (~10—17min/run),
`noise-floor` 又把慢 seed 跑两遍,且串行 → `n_tasks=2/iters=1` 要 ~80min。所以"分数恢复"这一环还没测到。

2. 分析 / Analysis

- "削弱什么"比"削弱多少"重要。prompt-weakening 在强 base model 上是无效削弱(它一轮自恢复),
GDPval ~0 gap 就是证据;真正可演化的 headroom 必须来自循环自恢复能力的硬缺口(工具 / 迭代预算)。
这把"该在哪个 benchmark 上跑演化"从直觉变成了判据:FAB 是对的,GDPval 不是。
- 早期 5 任务子集的 weak 0.743 > full 0.604 是假信号,full-30 纠正为持平 —— 提醒小样本结论必须全集复核

(这次 Phase-5 暂停的 `n_tasks=2` 同理,只能定性、不能下数值结论)。

- **机制泛化已在代码层兑现:** `Evaluator` 抽象把 `benchmark-specific` 评分(`GDPval` 多模态 `render` vs `FAB` 文本 `score_rubric`)藏到接口后, `run_levelb(cfg, benchmark)` 换 `Benchmark+seed` 即可跑两个 `benchmark`,不改 `loop`。
- **反作弊我们其实超出公开文献。** `ADAS/Gödel` 无防硬编码机制;`DGM` 是反面教材(能写代码 + 能看 `reward` 检测器
→ `agent` 改代码把检测器致盲)。我们的 `firewall`(答案无关诊断)+ `LeakageGuard` 双层,且把 `firewall` 设为 `canonical` 默认、`ahe_corpus` 仅作可切换的 `firewall-off` 实验档。
- **本质瓶颈与 AHE 一致:evolve-agent 强度。** `deepseek` 推理方向对(诊断/计划都对),但执行弱(空响应、`heredoc`、幻觉报成功)。三个 `blocker` 修完后管道才通 —— 这恰好印证 AHE "evolve-agent 是瓶颈"的结论。

3. 问题与困难 (待讨论) / Problems & Open Questions

- **[已解决] 三个 NexAU 基础设施坑**(`provider-pin` / 绝对 `work_dir` / 结构化文件工具)已修并写入 `checkpoint`,
属于"基底踩坑"而非机制问题。
- **[待讨论] 简单难度档signpost太强。** 当前 `FAB weak` 把恢复目标(工具描述文件)留在目录里 + 参考点名了招式,
所以"它会 `re-wire`"不能解读成能力。**讨论点:**升难度档的顺序 —— 先删描述文件(逼它推断能力),还是直接
删实现逼它写代码?后者很可能 `deepseek` 直接零增益(能力不足),那是否值得现在做,还是先用简单档拿到
`score-recovery baseline` 更有价值?
- **[待讨论] firewall 成本未量化。** `ahe_corpus` (`firewall-off`,不给 `gold`)vs `sanitized` (`firewall-on`)
谁的增益更高、`firewall` 到底"花"了多少分,需要一次对照。要不要把"让 `evolve agent` 读 `gold`"也作为上限消融
(预期增益=硬编码)来夹出区间?
- **[待讨论] 吞吐 vs 保真的取舍。** 把 `weak seed max_iterations` `40`→`12` 能省 3-4 倍时间,但会改 `weak` 的
绝对分(`0.388` 是 `40` 轮下测的)。简单档"看管道是否恢复"用低轮次够吗,还是必须保 `40` 轮可比?

4. 下周计划 / Next Week's Plan

1. 打三个吞吐补丁 + 跑完简单档完整 loop,拿到 score-recovery baseline。补丁:weak seed
max_iterations 40→~12、noise-floor 改固定小 margin(免跑第二遍 seed)、evaluate_dir
加并发。
预期产出: 0.388 → ? 的轨迹 + keep/rollback verdict,首次量化"演化是否真恢复了分数"。
2. 升难度档做干净的能力测试(依赖 1 先拿到 baseline):tier 1 删工具描述文件;tier 2 删实现逼真代
码合成;
并软化 NexAU 参考(去掉"re-wire"招式提示)。目的:把"管道通"升级成"evolve agent 能力"的诚
实证据。
3. firewall ON/OFF + gold-reading 消融:用 evidence_mode 一键切换,量化 firewall 成本与上
限。
4. 合并 Phase-5 分支 worktree-phase5-levelb-mechanism 到 main(当前所有 Phase-5 工作
未合并)。

阻塞项 / Blocked:无硬阻塞;计划 1 的吞吐补丁是后续一切跑分的前置。