

实验报告 / Experiment Report — QEA Quant/Finance Benchmark 权威性与演化适配性筛选

日期/Date: 2026-07-21 · 实验/Experiment: Benchmark Authority & Provenance Screen · 项目/Project: evolving-quant-agent (QEA) · 性质/Type: desk investigation, 未运行新 benchmark、未修改框架

0. 结论摘要 / Executive Summary

结论：本轮筛选已经明确了不同 benchmark 的权威性、任务形态、grader 和能力覆盖，但尚不能据此直接决定主演化应采用单一 benchmark 还是多个 benchmark。当前证据支持形成候选能力地图，而不是把某一种 benchmark suite 提前写成定案：

候选能力	代表 benchmark	当前可支持的判断
确定性 quant 任务	QFBench	reward 最适合观察代码、分析和产物执行能力是否发生变化
企业财务工作流	FINCH / FinWorkBench	更接近 spreadsheet、email、PDF 等组合式 enterprise workflow
投行业务交付物	BankerToolBench (BTB)	更接近 banker-authored / banker-validated 的端到端交付任务
权威专业任务迁移	GDPval Finance、PRBench Finance	适合检验提升能否迁移到专家构造的专业任务，但不宜直接视为高频演化 reward

单 benchmark 还是多 benchmark、是否需要 held-out、以及多 benchmark 应选择相近类别还是互补能力，仍需通过小规模实验决定。

最重要的三项校正：

- GDPval 已是 ICLR 2026 主会 Poster，不再只是 OpenAI report / arXiv。
- QFBench 目前是 NeurIPS 2026 submission，不是已录用论文；保留它是因为 quant 纯度与确定性 reward，而不是 venue。
- 没有候选可被称为“大银行内部数据集”。BankerToolBench 和 APEX-Agents 的优势是大行背景从业者参与创建/验证；数据本身主要是公共、标准化或模拟材料。

1. 实验过程与结果 / Process & Results

1.1 目标 / Goal

在不大改 QEA 框架的前提下，从已有候选中筛出一个或一组 benchmark，用于证明：evolver 能否持续改进 quant/finance worker，并把提升迁移到真实金融工作流。本轮额外加入“论文权威性、数据来源可靠性、使用许可”硬筛选，避免只因任务形态好接就选入。

1.2 方法与过程 / Method & Process

本轮是 source-grounded desk investigation，没有执行 adapter pilot。每项 benchmark 分别核验：

- Publication authority：顶会主会、Datasets & Benchmarks Track、Findings、非存档 workshop、arXiv/company benchmark 分开记录。
- Data provenance：真实企业 workspace、专业人士按实际工作构造、公开 SEC/IR/市场数据、比赛数据、模拟 world 分开记录。
- Reward reliability：确定性 unit tests、程序 metric、rubric + LLM judge、human pairwise 分开记录。
- Evolution compatibility：是否有标量分数、是否能反复运行、是否存在 hidden split、gold/rubric 泄漏、许可证是否允许 scaffold selection。
- Project fit：结合 QEA 已有 GDPval/FAB 实验结果与 DSBench source audit，区分“有权威”与“有可恢复 headroom”。

权威性评级口径：S = 顶会主会或正式顶会 Datasets & Benchmarks Track；A = Findings 或严格行业/企业数据流程；B = arXiv、company benchmark、非存档 workshop 或 community project。Venue、数据与 reward 分开判断，不用单一标签掩盖短板。

1.3 数据与结果 / Data & Results

A. 通过筛选的主要候选

Benchmark	Publication authority	数据 provenance	Reward / 复现	本项目角色	结论
GDPval	S: ICLR 2026 主会 Poster (official)	完整集 1,320 题、公开 gold 220 题；44 职业、9 行业；任务由平均 14 年经验的行业专家制作与多轮审核	human/model pairwise + 公共自动评分；公开 gold、rubric 和 reference deliverable 带来反复优化泄漏风险	冻结 external transfer	最高权威锚点；不做高频主演化 reward

Benchmark	Publication authority	数据 provenance	Reward / 复现	本项目角色	结论
PRBench Finance	S: ACL 2026 主会 Long Paper (paper)	总计 1,100 个 Finance/Law 任务; Finance 600、Finance-Hard 300; 182 名持 CFA/JD 或至少 6 年经验的专业人士参与	rubric 与代码公开; 主要依赖 LLM judge, 不是 deterministic verifier	finance reasoning confirm	强保留; 不能单独证明 agentic tool/workspace 能力
FINCH / FinWorkBench	A: ACL 2026 Findings, 不是 ACL main (paper)	172 个 composite workflows、384 个任务、1,710 张 spreadsheets、约 2,700 万 cells; 真实企业 workspace + 700+ 小时专家标注	数据、reference、预处理和 GPT-judge pipeline 公开; 自动评分仍有 judge variance	低频真实工作流 promotion	最接近 enterprise finance/accounting workflow
QFBench	B: NeurIPS 2026 submission, 未核实录用 (paper)	截至调查时约 87 个 practitioner-authored quant tasks, 覆盖 derivatives、risk、market microstructure、factor research、credit 等; 不是银行内部数据	Harbor/Docker + pytest; headline reward 严格 0/1; tests/oracle 公开, 需 evaluator firewall	高频主演化	工程核心首选; 用其他 benchmark 补足学术权威
BankerToolBench (BTB)	B+: arXiv + 非存档 workshop poster, 不是顶会主会 (paper)	100 个投行端到端任务; 502 名现/前 banker 参与整体研究, 其中 172 人直接创题/审题; 背景包括 BofA、Citi、GS、JPM、MS、UBS 等	weighted criterion score; Gandalf 可打开 Excel/PPT 并检查产物, 但核心仍是 agentic verifier	低频 banking core/checkpoint	最接近“大行经验来源”, 但不是大行内部数据
DSBench ModelOff 分支	S: ICLR 2025 主会 (paper)	466 个 analysis 任务来自 ModelOff/Eloquence challenge; 另有 74 个 Kaggle modeling 任务, 后者不能全部算 finance	答案比较、语义 judge 与运行 metric 混合; 第三方数据权利需单独审计	候选 analysis baseline/control, 尚未在当前仓库完成可审计 run	条件保留; 不替代 quant 主线
MBABench	B: arXiv preprint, 未核实录用 (paper)	end-to-end finance workbook, 来源包括 ModelOff、FMWC、Wall Street Prep	composite = Accuracy 50% + Formula 35% + Format 15%; 包含 LLM judge; 第三方数据许可不由代码 MIT 自动覆盖	Excel modeling secondary	先限于权利清楚、与 DSBench 去重的 ModelOff 子集

B. 降级、辅助或暂不进入 optimize 的候选

Benchmark	决定	主要证据与原因
APEX-Agents IB	从 optimize 池剔除	IB 有 160 题/10 worlds, 且有大行背景专家参与; 但官方 data card 明确 worlds 为 hypothetical/simulated, 并限定 exclusively for evaluation, 禁止 training、fine-tuning、parameter fitting。reward-driven scaffold selection 存在明显用途风险; 无书面许可时只做一次性 confirm。 data card
BigFinanceBench	blind/hosted confirm	928 题、52 名 finance SMEs、12 名 reviewer; 只使用 public sources。当前仅公开 50 题且完整暴露 gold/rubric, 剩余 held-out 题更适合作最终盲测。 paper
Hedge-Bench	confirm / watchlist	102 个任务来自专业 hedge-fund analysts 的推理讨论, 但机构和分析师匿名; 论文强调 expert steps, 发布 grader 实际仍使用 semantic judge, 不能称完全 deterministic。 paper
SpreadsheetBench	机制控制组	NeurIPS 2024 Datasets & Benchmarks Track; 912 个真实 Excel forum 问题与 OJ-style evaluator 很可靠, 但不是 finance 数据, 不能进入 Finance Overall Reward。 paper
FinMCP-Bench	routing 诊断轴	613 samples、65 tools; 当前 scorer 主要检查工具名称/序列, tool arguments 与最终财务结果验证不足, 不能代表完整 task success。 paper
OccuBench	robustness 辅助轴	100 个跨行业场景, 通过 LLM world model 注入 timeout、字段缺失、隐式数据退化; 适合测恢复能力, 但不是 finance-specific, 且 simulator/verifier 均有模型依赖。 paper
FinVault	finance safety gate	适合测攻击、越权和 benign over-refusal; 低 attack success 不等于高任务完成率, 不能把 1-ASR 当总 reward。 repo
From Tasks to Teams / M-SAEA	multi-agent safety audit	ACL 2026 Findings, 但它对已完成 trajectory 做 post-hoc 风险评估, 不是让 worker 执行金融任务的 benchmark。 paper
WorkspaceBench / 已核验的 MarketBench 版本	移出 finance 主表	workspace 或 market 机制可借鉴, 但任务内容不足以代表 quant/finance 专业能力。

C. “大银行数据”的事实边界

本轮未找到由 Goldman Sachs、JPMorgan、Morgan Stanley 等大型银行授权发布的内部交易、客户、模板或真实 deal-room 数据集。可成立的表述是：

Provenance 类型	Benchmark	可声称	不可声称
大行背景从业者参与	BTB、APEX-Agents	banker-authored / banker-validated	使用其前雇主的内部数据
真实企业 workspace	FINCH	来自真实企业 spreadsheet、email、PDF 等 artifacts	大银行正式发布的内部数据

Provenance 类型	Benchmark	可声称	不可声称
专家按工作实践构造	GDPval、PRBench	由资深专业人士基于 representative workflows 制作	输入必然来自真实客户项目
公共金融来源	BTB、BigFinance、Hedge-Bench、QFBench	SEC、IR、公开市场或 benchmark 冻结数据	Bloomberg、FactSet、CapIQ 或银行私有系统数据
专业比赛	DSBench、MBABench	ModelOff/FMWC 等专业建模案例	真实生产 banking workflow

BTB 的准确表述应为：“**Banker-authored and banker-validated, using public or standardized financial data.**” 其早期稿约 175 名 banker、任务 1–8 小时；当前扩展版为 502 名参与者、最长 21 小时。后续实验必须 pin paper/dataset 版本，不能把两版统计混用。

1.4 案例研究 / Case Study

Case A — GDPval：顶会权威不等于可演化 headroom

GDPval 现在拥有本候选集中最强的 publication authority 之一，但 QEA 的实测已经显示它不适合作高频主演化池：

GDPval worker	mean multimodal / gated	解释
weak: prompt 缩成一行 + bare shell	0.791 / 0.771	worker 在 episode 内自行恢复通用解题套路
full	0.797 / 0.772	与 weak 几乎相同
recoverable gap	约 0	没有足够可恢复差距供 evolver 证明升级

相反，FAB 删除 SEC retrieval bindings 后从 full 0.618 降到 weak 0.388，出现 0.230 的真实工具能力 gap（本地证据见 [docs/BASELINES.m d](#)）。

这个对照证明：**benchmark** 的论文权威性回答“值得信吗”，**headroom** 回答“能演化吗”；两者必须分别验证。因此 GDPval 被保留为 frozen transfer，而不是被淘汰。这里仅声称 FAB 存在 headroom；完整 scored evolution 当时在 candidate evaluation 前暂停，尚不能声称已自动恢复该 gap。

Case B — BTB：银行从业者 provenance 不等于银行内部数据

BTB 是“银行行业真实性”最强的候选，但如果只看到 Goldman/JPM/MS 等机构名称，容易错误写成“大银行数据”。进一步核验后，正确链路是：

大行背景 banker 参与 survey / task analysis / authoring / review
+
真实上市公司、SEC filings、标准化 market-data/VDR
->
模拟真实 junior-banker workflow 的 benchmark

论文明确不包含 internal templates、真实 deal-room archive、机密交易或客户 PII。因此 BTB 可作为 high-fidelity banking checkpoint，却不能作为“银行官方内部数据”证据。该例说明：**专家 provenance 与底层数据 provenance 必须拆开写**。

1.5 当前证据能回答什么、仍需验证什么 / What the Evidence Resolves and What Remains Open

本轮筛选已经回答了“每个 benchmark 更接近测什么”，但还没有回答“哪一种 benchmark 组织方式最适合驱动演化”。现有证据只能支持以下能力地图：QFBench 更接近确定性的 quant coding、risk、factor、backtesting 与多文件产物执行；FINCH 更接近企业财务与 accounting workflow；BTB 更接近投行业务交付物；GDPval/PRBench 更适合作为专业任务上的迁移观察。这里的定位不等于已经确定它们必须组成同一个 suite。

单一 benchmark 演化：归因更清楚，但能力范围可能较窄

如果主演化只使用一个 benchmark，reward 定义、grader、任务格式和成本都更容易控制，也更容易判断一次 worker 修改是否真的改善了同一种任务分布。它的局限是：即使分数提高，也可能只能说明 worker 更适应该 benchmark，而不能说明 quant、企业财务 workflow 和 banking deliverable 等多种能力同时提高。

多 benchmark 演化：可以探索多能力，但解释更复杂

如果同时使用多个 benchmark，可以把研究问题扩展为：同一个 evolver 能否改善多种能力，例如 QFBench 所代表的 quant 执行能力、FINCH 所代表的企业财务 workflow，以及 BTB 所代表的投行业务交付能力。与此同时，综合结果也可能受到 routing、benchmark 权重、grader 类型和输出格式差异影响。因此，多 benchmark 分数变好不一定等于底层能力普遍变好，需要通过逐 benchmark 结果和迁移测试拆开解释。

held-out 测试：单 benchmark 与多 benchmark 都需要明确边界

对于单一公开 benchmark，反复使用同一批任务进行演化容易把 benchmark-specific 适配误写成泛化，因此是否建立按 task family 或 workflow lineage 隔离的 held-out 测试，是首先要决定的方法学问题。对于多 benchmark，还需要进一步判断：每个 benchmark 是否都要保留自己的 held-out 部分，以及未参与主演化的另一个 benchmark 能否作为 cross-benchmark transfer test。当前报告只提出这些设计选项，不提前给出结论。

多 benchmark 的两种候选组合

一种思路是选择任务类别相近的 benchmark，例如 GDPval Finance 与 FINCH，以观察同一大类专业 finance workflow 上的演化与迁移；另一种思路是选择能力互补的 benchmark，例如 QFBench、FINCH 与 BTB，分别覆盖 quant、企业财务 workflow 和 banking deliverable。前者更容易比较，后者覆盖面更广。具体采用哪一种，应由小规模 pilot 的实际效果决定。

证据边界： 本轮尚未运行上述单 benchmark / 多 benchmark 对照，也没有测得跨 benchmark transfer、统一 reward、adapter 兼容性或综合演化收益。以上内容是下一步实验需要检验的假设，不是已经成立的结果。

3. 问题与困难（待讨论） / Problems & Open Questions

- 1. 应该使用单一 benchmark 演化，还是使用多个 benchmark 演化？ 如果使用多个 benchmark，是否可以有意识地演化多种能力，例如 QFBench 对应的 quant 分析与执行能力、FINCH 对应的企业财务 workflow，以及 BTB 对应的 banking deliverable 能力？
- 2. 不同演化方案应如何设计测试边界？ 如果使用单一 benchmark，是否必须设置 held-out 测试，以区分真正的泛化与 benchmark-specific 优化？ 如果使用多个 benchmark，它们应该来自相同或相近类别，例如 GDPval Finance 与 FINCH，还是应该覆盖互补能力？

4. 下周计划 / Next Week's Plan

以下是待讨论的初步计划；目标是先用最小实验观察实际效果，再决定是否扩大接入。

- 1. 初步敲定 benchmark 方案。 选出一个单 benchmark 方案和一个多 benchmark 候选方案，明确各自希望观察的能力与最小任务集合。
- 2. 运行小规模测试。 每个方案只选少量有代表性的任务，先比较演化前后的分数、完成情况和失败类型，不立即扩展到完整 benchmark。
- 3. 检查提升发生在哪里。 区分提升只出现在主演化任务内，还是也能迁移到 held-out task 或另一 benchmark；同时记录结果是否稳定，而不只看一次均分。
- 4. 根据实际效果再做决定。 如果小测能显示清楚的可恢复提升，再细化 benchmark、held-out 和后续接入方案；如果没有明显效果，先调整 benchmark 选择或任务组合。

当前状态 / Current status： benchmark 方案尚未最终敲定；下一步只进行小规模效果测试，不开展 license audit 或大规模接入。