

实验报告 / Experiment Report - QFBench 30-Task × 5-Iteration E2B Evolution

日期/Date: 2026-07-25 | 实验/Experiment: **qfbench-30x5-20260725** | Benchmark commit: **024921eb507fcc0c4ffe3e0a96802724be1ae84a**

1. 实验过程与结果 / Process & Results

- 目标 / Goal：把 QFBench 从 3 optimize / 2 held-out 的小 pilot 扩展到预注册的 20 optimize / 10 held-out，并用 5 轮真实 E2B evolution 检查 reward firewall、resume 和更低的单题敏感度。
- 结论 / Headline：工程链路完成 140/140 个 official score records，五个 candidate 全部被正确 rollback；但 3 个 verifier templates 的 offline cache 缺陷污染了 14 个 attempts，因此 performance score 只能视为 provisional，不能声称 evolution gain。

方法与过程 / Method & Process

```
30-task manifest (20 optimize + 10 held-out, 6 domains)
-> seed optimize + seed held-out
-> 5 × proposer edit + 20-task candidate evaluation
-> domain-regression gate + 0.02 noise-floor gate
-> final held-out on the surviving incumbent
```

配置固定为 **deepseek/deepseek-v4-pro**、**concurrency=8**、global E2B cap 12。Worker 可访问受限的 model-provider endpoint；official tests/test reference data 只进入独立、无网络的 verifier sandbox；未上传或运行 official solutions。共享 base 被复用；60 个 task-role templates 中 10 个复用、50 个在 05:21-05:43 UTC 发布。完整命令和 resume 规则见 runbook。

调度为 **20 + 10 + 5×20 + 10 = 140**。从首个 attempt artifact 到最终 lifecycle cleanup 的实测跨度约 5 h 17 min。140 个 worker 中 4 个 timeout 后按预注册规则记 0 并跳过 verifier，因此实际生成 136 个 verifier、合计 276 个 sandbox lifecycles；最终 276/276 均 **cleaned_up=true**，exact-ID reaper dry-run 为 0 pending。模型 token、provider cost 与 E2B billing total 未写入 artifact，故记为 not measured。

数据与结果 / Data & Results

Observed optimize incumbent 为 0.500000，五轮没有 keep：

Iter	Candidate overall	关键 domain delta	Gate result
1	0.490278	risk_credit -0.083333	rollback：domain regression
2	0.418452	systematic_strategy -0.500000	rollback：domain regression
3	0.465278	risk_credit +0.041667, systematic_strategy -0.250000	rollback：domain regression
4	0.529167	derivatives +0.333333, systematic_strategy -0.250000	rollback：domain regression
5	0.513194	全部 domain 非负；净增益 +0.013194	rollback：未超过 0.020000 noise floor

Held-out observed domain macro 从 0.666667 降到 0.583333（**-0.083333**），task mean 从 0.7 降到 0.6（**-0.1**）。最终变化来自 **fx-forward-cross-rate: 1→0**；其余可评分 held-out 题保持不变。**form4** 的 seed/final 都受 offline cache 污染，不能据此判断真实表现。

与 2026-07-24 pilot 的比较如下。两个 run 的 overall 使用不同 panel，只能作 contextual comparison，不是 paired estimate：

Metric	3-task pilot	30-task run
Optimize / held-out tasks	3 / 2	20 / 10
Iterations / official scores	3 / 16	5 / 140
Optimize seed→final	1.0000→1.0000	0.5000→0.5000
Held-out domain macro	1.0000→0.5000	0.6667→0.5833
Keep / rollback	0 / 3	0 / 5
One binary held-out task 对 task mean 的影响	0.5	0.1

Shared optimize tasks 中, **historical-var-data-prep** 和 **momentum-backtest** 都是 1.0; **evt-pot-var** 从旧 pilot 的 1.0 变为新 seed 的 0.833333。Shared held-out 中, 旧 pilot 的 option audit 为 **1→0**、FX 为 **1→1**; 新 run 为 option **0→0**、FX **1→0**。这再次显示 model sampling variance 并未因题量扩大而消失。

案例研究 / Case Study

Case A - firewall 确实工作。Iteration 4 的 overall 从 0.500000 提升到 0.529167, derivatives、execution 和 risk_credit 分别提高 0.333333、0.050000、0.041667; 但 systematic_strategy 下降 0.25。resume.json 因此记录 **kept=false** 和 **domain regression: systematic_strategy**。这是“aggregate improvement 不得掩盖 domain harm”的端到端证据。

Case B - offline isolation 成立, 但 cache preflight 不完整。3 个官方脚本写成 **if uvx ...**, 发布时 parser 只识别裸 **uvx . . .**, 对应 manifests 的 **verifier_uvx_warm_command** 为 **null**。无网络 verifier 随后无法从 registry 补齐 pytest, 14 个 attempts 得到 **reward=0, tests_passed=0, tests_failed=0**。受影响的是 delta hedging 6 次、swap bootstrap 6 次、form4 2 次。根因已用 RED→GREEN test 修复, 本轮授权没有包含额外 template rebuild 或 score repair。

2. 分析 / Analysis

- 1 扩大题量显著改善了分辨率, 但没有估计 stochastic variance。Held-out task mean 的单个 binary task 步长从 0.5 降到 0.1; 不过同一 seed worker 的 FX 仍出现 **1→0**, 所以 30 题不能替代 independent model seeds。
- 2 双 gate 提供了有意义的安全约束。Iteration 4 证明 domain firewall 会拒绝“总分上涨但局部受损”; Iteration 5 证明无 domain regression 时, 低于 0.02 的小增益仍不会晋升。
- 3 没有 evolution gain。五轮均 rollback, final worker 与 seed 相同, optimize trajectory 只有 0.500000。Held-out 下降是对同一 worker 的独立采样, 不是已接受 mutation 的 regression。
- 4 当前 score 不是正式 authority claim。14 个 infrastructure zeros 横跨 optimize 与 held-out。它们在 observed table 中是固定 0, 但 counterfactual official rewards 未知, 可能改变 candidate delta 或 held-out level; 因此只能保留工程与 gate 行为结论。
- 5 主要成本风险来自 task-specific long tail。**localvol-barrier** 可接近 2400 s, **yield-curve-bond-immunization** 多次接近 1800 s; 提高 concurrency 无法消除轮末等待。应按 task 记录 runtime distribution 和 budget, 而不是统一缩短 timeout。

3. 问题与困难（待讨论）/ Problems & Open Questions

- 1 如何修复已完成 run 的统计身份? 建议发布 3 个新 verifier identities, 并在新授权下只修复 14 个 contaminated scores; 需要决定是生成 superseding repair run, 还是在保留原始 artifacts 的前提下重算同一 schedule。
- 2 infra failure 是否应进入 reward? 已完成 run 中, shell 可写 **reward.txt=0** 且 exit 0, 即使 CTRF 从未生成。Local trusted parser 现已对明确的 offline dependency-resolution error fail closed; 仍需决定其他“expected CTRF missing”路径应记录可恢复的 **verifier_error**, 还是直接中止 checkpoint。
- 3 需要多少 seed repetition? 10 个 held-out tasks 降低了 panel granularity, 但 FX 的 **1→0** 表明至少还需固定 panel 的多次 independent seed run, 才能估计 uncertainty/noise floor。

- 4 费用可观测性仍缺失。50 builds、140 worker scores 与 136 verifier lifecycles 已执行，但实际 E2B 和 provider 金额无法从 artifact 复核。

4. 下周计划 / Next Week's Plan

- 1 固化 verifier preflight hardening。Local code 已识别 `if uvx`、对未知 `uvx` wrapper fail closed，并拒绝明确的 offline dependency-resolution zero；下一步把 30-task manifest preflight 纳入 CI 和 paid-publication checklist。
- 2 申请最小 paid repair authorization。只重建 delta/swap/form4 的 3 个 verifier templates，先做无模型的 offline cache canary，再修复 14 个受污染 scores；不上传 official solutions。
- 3 生成 superseding comparison。修复后重算五轮 gate、held-out delta 和与旧 pilot 的 shared-task table；旧 run 保持 immutable，并由新 decision 明确 supersede。
- 4 估计模型方差。对固定的代表性 optimize/held-out 子集运行至少 3 个 independent seeds，分开报告 task-panel variance 与 model-sampling variance。
- 5 补齐 cost telemetry。在 attempt/run manifest 中持久化 provider usage、token/cost（若 API 提供）和 E2B lifecycle duration/billing metadata；未知值继续明确标为 not measured。

主要 artifacts：`results/qfbench/qfbench-30x5-20260725/resume.json`、`result.json`、`validity-audit.json`、`comparison-to-pilot-3.{json,md}`、`data/qfbench/MANIFEST_30.json` 和 `output/qfbench-e2b-images/20260725_30x5_024921eb/`。