

实验报告 / Experiment Report — Harness Evolution

机制验证路线

日期 / Date: 2026-08-18

覆盖范围 / Scope: 2026-08-11 至 2026-08-18

Benchmarks: QFBench、QuantCodeEval

报告边界 / Boundary: engineering mechanism validation, 不是 benchmark-wide 或论文级最终结果

结论先行 / Executive Summary

过去一周已经把系统从“Evolver 能不能完成一次合法决策”推进到“Evolver 产生的多组件 harness 不能让 fresh Worker 得到 official binary reward”。目前最强结果是：R3 Evolver 产生并通过 admission 的 candidate harness，在一次从 public T26 task 开始的 fresh Worker 中达到 **17/17、reward 1**。这证明了候选 harness 可以产生实际二元收益，但还没有证明完整的 autonomous search：AP-1 的 repair probe、候选晋级和最终确认仍由实验者组织。

因此，当前结论不是“已经完成全自主进化”，而是：

控制闭环、full-harness mutation、runtime experience、component activation、answer-rich attribution 和 fresh binary success 均已有实验证据；剩余核心门槛是 Evolver 自主选择实验、消费实验反馈，以及从 shell-only H0 自主 bootstrap。

整体机制路线如下：

合法 ACT / ABSTAIN

- > full-harness component mutation
- > component smoke + Worker activation
- > runtime experience retained across rounds
- > domain-specific state localization
- > answer-rich optimize feedback to Evolver, blind Worker execution
- > component-level repair and official score
- > autonomous experiment choice (AP-2M, next)
- > autonomous bootstrap from H0 (AP-3, next)

1. 机制验证路线与实验结果 / Mechanism Validation Route

报告按机制依赖组织，而不是逐日列出 run。每个节点回答：机制是什么、要验证什么、什么数据能够验证、实际得到什么、现在处于什么状态。

节点 1 — Evolver 能否诚实完成搜索闭环

Mechanism。 A6 ME1—ME10 建立 bounded exploration、probe、checkpoint 和 terminal ACT/ABSTAIN 协议，使证据不足时可以合法停止，而不是被迫生成 candidate。

Question。 Evolver 能否在真实 provider path 中累计证据、执行 probe、保存 checkpoint，并以与证据一致的 terminal decision 结束？

Validation signal。 合法 terminal decision；decision 与 checkpoint 绑定；candidate write lock 在 ABSTAIN 时保持关闭；若 ACT，则必须出现非空 harness diff、admission 和 candidate evaluation。

Evidence and result。 ME7 首次完成端到端合法 ABSTAIN；ME10 在三个 exploration epochs、三个 real probes、三个 reload-verified checkpoints 后再次得到更强的 calibrated ABSTAIN。ME1—ME10 共记录 172 logical requests、170 个 HTTP-200 responses、至少 5,798,107 tokens 和 USD 0.3520366696。整个系列没有产生合法 ACT、non-empty diff 或 candidate score。

Status。 Terminal mechanism validated；harness benefit not tested。瓶颈从 control flow 转移到 evidence sufficiency 与 semantic identifiability。

Next dependency。 必须让 Evolver 能操作真实 harness component，并让后续轮次看到之前的成功与失败。

节点 2 — 搜索对象能否从 prompt 扩展到完整 harness，并保留跨轮历史

Mechanism。 QuantCodeEval adapter 将 mutation surface 扩展为 NexAU full harness，包括 systemprompt、tools、tool descriptions、agent configuration、skills 和 middleware；每轮保留 prior candidate、diff、decision、component smoke 和 score outcome。

Question。 Evolver 是否能看到上一轮改动及其结果，从 prompt-only mutation 转向 executable component，并根据历史 refine、rollback 或 abstain？

Validation signal。 下一轮实际读取 prior entry 和 candidate source；产生非 prompt-only diff；component 可调用；完整 admission 通过；candidate 在 Worker 中被触发。

Evidence and result。

- 初始五轮 PGBHS 都只修改 systemprompt.md。T16 始终作为保护任务，T24 多次没有 artifact；第 5 轮把 T24 从 59 requests 后无 artifact 改为 10 个 T24 requests 内产生可评分 artifact，并达到 15/17，但所有 candidate 最终 rollback，官方 incumbent 仍为 H0 [1, 0]。五轮 search 共 200 requests、6,152,505 tokens、USD 0.1532859160。
- v2 deterministic canary 证明 round 2 能读取 round 1 的 rejected patch，改为新增 executable tool、tool description 和 agent registration，并在达到 fixture target 后提前停止，不再固定运行五轮。
- real r1—r4 逐步修复 role attribution、history projection 和 decision schema 后，r4 首次完成合法 full-harness ACT 与 admission。r8 随后生成并激活四文件 quant audit component；T24 从 H0 15/17 提升到 16/17、T16 保持 18/18，但 binary vector 未变。
- r9 继续扩大 static audit 后，T16 降到 3/18，T24 无 artifact；该负结果否证了“继续堆叠静态规则”作为主要搜索方向。

Status. Full-harness manipulation and cumulative history validated。早期 fixed five-iteration prompt search 已完成其工程验证作用，不是当前方法本体。

Next dependency. 历史不仅要可见，还要能帮助 Evolver排除错误机制、定位可复用的 quant state。

节点 3 — Runtime experience 能否定位真正有辨识力的 quant state

Mechanism. 将 Worker trace、artifact、public-definition retrieval、probe outcome 和 prior component result保存为 answer-free runtime experience；同时引入 declarative quant invariant，把 public quantity vocabulary 绑定到实际 operation。

Question. 累计 history 是否能帮助 Evolver发现“Worker 自己写的 probe 虽然通过，但并不区分正确与错误解释”？domain component 是否能通过显式 state binding 修复该问题？

Validation signal. Evolver 能指出 prior probe 对成功/失败样本无区分力；新的 component 对错误/正确语义产生不同观察；fresh Worker score 改善并在 protection task 不退化。

Evidence and result. 两次 autonomous activation 都读取了历史，但分别在 23 和 22 requests 后 calibrated ABSTAIN。历史对比显示四个 T12 分支的 free-form probe 最终都通过，而 official result 从 8/16 到 16/16 不等，说明该 probe 是 self-confirming。实验者随后 seeded declarative invariant：初版仍允许“文字说 average、工具算 additive sum”，只得 8/16；将 average_return、cumulative_return 和 additive_sum 绑定到公开定义后，两次独立 T12 Worker 都得到 16/16，T19 protection 得到 18/18。该节点合计 137 requests、5,102,462 tokens、USD 0.1547955976。

Status. Runtime localization and component viability validated；final invariant was not autonomously discovered。

Next dependency. Evolver 必须能 reuse/refine component，也要能在历史否认某个 intervention 后停止重复它。

节点 4 — Evolver 能否利用负反馈 refine component，并处理组件交互

Mechanism. Component ledger 记录 activated / unsupported / pending / supported；下一轮读取上一轮 exact intervention、Worker activation 和 official outcome，选择 REUSE / REFINE / COMPOSE / ABSTAIN。

Question. Evolver 是否会因为真实负结果改变下一轮决策？它能否区分“quant component 无效”“component hook 不可达”和“多组件相互干扰”？

Validation signal. 不重复已证伪 intervention；对证据不足的分支 calibrated ABSTAIN；用 runtime reachability falsify 错误 hook；修复后在真实 Worker 中触发；组合后的 score 单独解释。

Evidence and result.

- T18: Evolver 自主提出 warmup-boundary skill，fresh Worker 确实加载 skill、执行 exactly-120 fixture 并改变 implementation，但 T18 仍为 16/18。下一轮读取这一结果后明确排除该机制，并因 percentile/NaN conventions 无法由 public evidence 区分而合法 ABSTAIN。两轮分别使用 USD 0.0656560688 和 USD 0.0492410744。

- T24 delivery: 第一版 `after_model guard` 属于正确 component family, 但 installed runtime 在 hook 前已经抛错, 因此不可能触达; 第二轮改为 reachable `wrap_model_call` middleware, 并在真实 Worker 中连续恢复两次 empty response, 使 Worker 最终交付 artifact。组合后的 quant score 却从 prior 16/17 降到 11/17, 说明“delivery recovery 有效”不等于“整体 harness score 提升”。该阶段 142 requests、11,733,043 tokens、USD 0.178233636。

Status。 Feedback-driven refine、reachability diagnosis 和 real middleware recovery validated; component composition benefit not validated。

Next dependency。 需要跨 benchmark 的共同 experience interface, 同时避免把 task-specific checker 当成通用 component。

节点 5 — 同一搜索接口能否跨 QFBench 与 QuantCodeEval 工作

Mechanism。 Thin cross-benchmark adapter 共享 task cards、runtime experience、component cards 和 search operators; Worker contract 与 official verifier 仍由各 benchmark 自己执行。

Question。 同一 Evolver interface 能否在 evidence 不足时对 QFBench abstain, 又在 QuantCodeEval 有足够 runtime contrast 时自主合成 component, 而不是强制复用同一个模板?

Validation signal。 不同 benchmark 上产生与证据匹配的不同决策; QuantCodeEval candidate 是 multi-file executable mutation; Worker 实际调用 component; target repeat 与 protection 单独报告。

Evidence and result。 Zero-model preflight 建立了 QFBench 四个 task cards 和 QuantCodeEval T26/T27 可执行环境, 14 个 focused tests 通过, 未产生模型费用。live breadth 中, QFBench `swap-curve-bootstrap-ois` 的 task-only 与 history-enabled arms 都因 public evidence 无法区分 forward definition 与 valuation convention 而 semantic ABSTAIN。T26 H0 为 13/17; Evolver 自主生成五文件 public-clause audit/revision component; 两个 candidate Workers 都调用 component 三次, 但分数分别为 14/17 和 12/17, 收益不稳定; T19 protection 为 18/18。整组 live experiment 使用 183 requests、8,231,008 tokens、USD 0.2101171912。

Status。 Cross-benchmark navigation、autonomous ACT 和 real activation validated; stable benefit not validated。Task-specific assertions 没有解释 T19 的表现, 较可能有用的是 read-contract、independent-check、revise、re-audit workflow。

Next dependency。 对 optimize task 给 Evolver 更精确的 post-run diagnostic, 同时保持 Worker blind, 以提高 attribution 分辨率。

节点 6 — Answer-rich Evolver 能否定位可复用组件, 而不把答案交给 Worker

Mechanism。 对声明为 optimize 的 T26, trusted coordinator 在评分后向 Evolver 提供 item-level answer-rich diagnostic; fresh Worker 仍只看到 public task、data 和 candidate harness。答案可帮助 Evolver 归因, 但不得写入 reusable component。

Question。 更精细的错误对比能否让 Evolver 从宽泛 static rules 转向具体 quant-contract component, 并使 predicted properties 在 blind Worker 中改善?

Validation signal. Evolver 自主选择 component locus; candidate 不包含 expected values; Worker 真实调用 component; Evolver 预测的 properties 改为 PASS; 独立 repeat 保持结果。

Evidence and result. Evolver 从 retained 13/17、14/17、12/17 attempts 归纳 declared–formula–realization 问题, 新增 quant–contract auditor、tool registration 和 revise/re–audit workflow。第一名有效 blind Worker 调用 auditor 14 次并达到 16/17; 独立 repeat 调用相关 component 12 次, 再次达到 16/17。两次均通过全部 Type B, Evolver 明确预测的 B5/B9 均从失败转为 PASS; A10 numeric identity 仍失败。完整 retained lineage 使用 139 requests、5,841,009 tokens、USD 0.2923158504。

Status. Answer–rich attribution、blind–Worker boundary 和 repeated property benefit validated; binary gain remained open at this node。

Next dependency. 必须区分“最终数值不一致”的表象与 estimator pipeline 中真正错误的 state transition。

节点 7 — Quant–specific state semantics 能否解释 residual binary failure

Mechanism. 将 CV split membership、moment–estimation membership、fold–local scaling、first/second moment 和 runtime output shape 视为显式 quant state, 而不是继续扩充长列表式 failure taxonomy。

Question. A10 的 residual mismatch 是 grid resolution、formula surface, 还是 sample–set/state propagation 错误? static semantic checks 是否足以保证 Worker artifact 稳定?

Validation signal. Causal ablation 能单独区分竞争假设; official verifier 从 16/17 变为 17/17; 新的 autonomous component 在 blind Worker 中不产生新的 runtime crash。

Evidence and result.

- Grid–only change 仍为 16/17, 否证了“更多 grid points 足以解决 A10”。
- Causal ablation 找到真正原因: CV complement 的非连续月份集合被下游用首尾日期重建成连续区间, held–out fold 因此重新进入 moment estimation; 同时 fold–local quantities 复用了 full–sample state。修复 set membership、fold–local scaling、population covariance 与 grid 后, trusted zero–model replay 得到 17/17、reward 1。这个结果证明 root cause, 但不是 fresh autonomous lineage。
- 8 月 18 日 R3 autonomous estimator candidate 的 synthetic contrasts 仍有 false rejection; generalized R4 repair 使 fresh Worker 达到 15/17。R5 再扩充 first/second–moment 与 public–scope static checks, 虽然 synthetic pairs 全部通过, 但 blind Worker 因 multi–output OLS shape mismatch 只得 3/17, 十一项 property crash。由此可见 static semantic localization 不能替代 executable runtime probe。
- Provider recovery 同期确认 reasoning–only SSE empty response 可以被识别, 但 full–budget serial fallback 会超过 downstream timeout; 最终实现改为一次 bounded low–reasoning recovery。它已通过 focused tests, 尚未在新的 paid Worker 中验证。

Status. Causal estimator–state root cause validated; static–check stability refuted; fresh autonomous binary still not closed at this node。

Next dependency。 与其继续人工枚举 failure class，应让 Evolver 能发起一个真实、短程 Worker experiment，并依据 artifact、trace、score、runtime 和 cost 自己更新 candidate。

节点 8 — Evolver-produced harness 是否已经产生 official binary benefit

Mechanism。 AP-1 使用同一个 3/17 failed artifact，分别交给 parent harness 和 R3 Evolver-produced candidate harness 做短程 repair；随后把 candidate harness 用于一次从 public task 开始的 fresh Worker。

Question。 Candidate bundle 是否在实际 Worker repair 中有帮助？它能否在不是 seed-artifact repair 的 fresh run 中产生 17/17？

Validation signal。 Paired repair 中 candidate 相对 parent 有 property gain；fresh Worker 从 public task 产生新 artifact；official verifier 达到 17/17；同时明确区分“harness 有效”与“实验选择完全自主”。

Evidence and result。 Paired repair 的 parent 与 candidate 各使用 11 requests。Parent 得到 12/17，candidate 得到 14/17，property delta 为 +2；candidate 更慢、更贵，因此是 **score-helpful**，不是 **efficiency-helpful** 或 **binary-helpful**。随后 fresh candidate run 使用 59 requests、3,284,491 tokens、USD 0.120627420 和 1,766.607 秒，得到 Type A 7/7、Type B 10/10、总计 17/17、reward 1。所有请求均走 DeepSeek，configured fallback 未触发。

Status。 Fresh candidate-harness binary success validated once。Complete autonomous search not yet validated。AP-1 的 seed、repair instruction、promotion 与 final evaluation 仍由 experimenter 组织；static auditor 对 14/17 artifact 仍有 false negatives，所以收益应归于整个 workflow bundle，不能归因于 auditor accuracy。

案例研究 / Case Study

正向案例：candidate harness 从 paired repair 走到 fresh 17/17。 同一个 3/17 artifact 在 shell-only parent 下修到 12/17，在 R3 candidate harness 下修到 14/17，说明 candidate workflow 能给 Worker 带来额外修复能力。随后不再提供 seed artifact，而是让相同 candidate harness 面对 public T26 task 从头工作；Worker 在 59 turns 中完成 76 次 tool calls，最终 artifact 在 official verifier 中通过全部 17 个 properties。这个案例证明 harness benefit 可以跨越“修旧 artifact”和“从 public task 生成新 artifact”两种工作模式；它尚未证明 experiment selection 自主，因为 paired probe 与 promotion 由实验者决定。

负向案例：static contrasts 全通过，fresh Worker 仍从 15/17 降到 3/17。 R5 component 能区分 synthetic first/second-moment 与 public-scope wrong/correct pairs，也接受 retained 17/17 repair；但 fresh Worker 写出的 multi-output OLS helper 使用不兼容 array shapes，导致十一项 property crash。这个案例直接否认“component smoke PASS 就代表 Worker integration 稳定”，并给出下一步机制要求：Evolver 的 probe 必须能够执行 public entry points、检查 output shape/finiteness/no-crash，并把真实 traceback 带回下一轮，而不是只扩大 static rule set。

2. 跨节点分析 / Analysis

2.1 已经验证的不是单一 prompt trick，而是一条 component lifecycle

证据已经覆盖完整生命周期：Evolver 能提出 multi-file component、通过 smoke/admission、让 Worker 真正调用、观察 score 与 runtime outcome、把失败保留到下一轮，并在证据不足时停止。r8、T18、T24 delivery、T26 breadth 和 answer-rich refinement 分别验证了这一链条的不同部分。

2.2 Runtime experience 的价值主要是排除和定位，不保证自动发现最终答案

T18 历史使 Evolver 不再重复 warmup-boundary；T12 历史揭示 free-form probe 无区分力；T24 reachability history 把错误 hook 改成可达 middleware。这些都是有效 learning-from-runtime。另一方面，T12 的 public-quantity binding 和 T26 的 CV set semantics 仍先由实验者因果定位，说明当前缺口是 Evolver 自己设计有辨识力的实验，而不是“看不到上一轮”。

2.3 Domain specialization 应表达为可扩展 state map，而不是穷举答案

有效的 quant abstraction 是 sample membership、moment scope、unit state、temporal endpoint、artifact lifecycle 和 runtime shape 等 pipeline state。它们指导 Evolver 选择检查或实验，但不把 T26 property answer 编码进 Worker。R5 的 3/17 负结果表明，仅有更长的 static failure map 会产生 false confidence；domain map 必须连接到 executable observation。

2.4 当前最强 performance 结果与最强 autonomy 结果仍是两条证据

- Performance: R3 candidate harness 的 fresh Worker 已达到一次 17/17。
- Autonomy: Evolver 已能自主选择并实现 component，也能使用历史 refine/abstain；但尚未自主选择 AP-1 类型的 probe、读取 probe 结果后再决定 final candidate。

下一步 AP-2M 的作用就是把这两条证据连接起来；AP-3 再检验能否从 H0 起步。

3. 当前问题与结论边界 / Open Questions and Claim Boundary

1. 完整自主性仍未验证。目前不能声称 Evolver 已能自主完成 history search -> experiment design -> feedback update -> final submission。
2. 17/17 只出现一次 fresh candidate run。它证明可行性，不证明稳定性；但当前优先级应先验证自主闭环，再决定是否重复。
3. Component attribution 仍不充分。AP-1 的 bundle 有效，但 static auditor 本身仍误报；真正贡献可能来自 contract reading、revision discipline、runtime probe 或它们的组合。
4. Static smoke 不能代表 Worker integration。R5 synthetic tests 通过而 fresh Worker 3/17，是当前最明确的反例。
5. Cross-task generalization 尚未建立。T19 是 protection，不是 matched positive transfer；QFBench arms 验证了 semantic abstention，但没有 score gain。
6. 大规模 scheduler 暂缓。长尾 task 与异步成本调度是后续 scaling 问题；在自主闭环尚未跑通前实现复杂 scheduler 会稀释主要机制问题。

4. 下一步实验计划 / Next Experiment Plan

下一步不再新增一轮人工 failure-class mutation，而是先验证 Evolver 是否拥有完整、最小的自主实验能力。

P1 — 实现 AP-2M minimum closed loop

What。 在现有 QuantCodeEval runner 上增加两个 Evolver decision rounds 和一个 Evolver-authored `experiment_spec`。Round 1 自己选择 history、artifact 或 from-scratch mode、Worker instruction、component、probe budget、prediction，以及什么 observation 会改变决策；coordinator 只执行一次合法 probe；Round 2 收到 artifact、trace、official optimize properties、runtime、requests、tokens 和 cost 后，选择 retain、refine、rollback、compose、submit 或 `ABSTAIN`。

Why。 这是当前唯一缺失的最小机制：Evolver 不仅看到历史，而且能自己选择下一条真实 observation，并用 observation 更新 harness。

Implementation boundary。 复用现有 runner、candidate workspace、Worker executor 和 verifier；使用普通 JSON 记录，不先建立通用 experience service，不实现 scheduler，不扩展到多个 benchmark。

Local validation。 用 deterministic fake 验证：Round 1 能写合法 experiment；coordinator 能执行；Round 2 能读取真实结果并改变决策；final candidate 能独立评分；`ABSTAIN` 始终合法。只覆盖 happy path 和已经观察过的 malformed decision/empty artifact。

P2 — 运行一次 AP-2M warm-history autonomy canary

Setup。 使用 pre-AP-1 history catalog；两轮 Evolver；一个 10-12 iteration Worker probe；一个合法 candidate 的 independent final T26 Worker；concurrency 1；建议总 provider cap USD 0.25。当前 17/17 candidate 作为 experimenter-side reference，不把 AP-1 prompt 或 expert root-cause summary 写进 Evolver assignment。

Primary gates。

- `autonomy_feasible`：Evolver 完成 self-selected experiment 和 second decision；
- `feedback_driven`：Round 2 明确依据 Round 1 observation 改变、保留或回滚；
- `component_helpful`：self-selected component 改善 property、修复 predicted runtime fault，或以更低成本达到同等结果；
- `benchmark_helpful`：independent final candidate 相对其选定 parent 有 official property gain；17/17 单独标记 binary success。

AP-2M 不需要超过当前已知 17/17 上限。它的首要结论是“自主 experiment loop 是否成立”；若它自主选择较弱 parent 并最终达到或保持 17/17，这是很强的机制结果。grounded `ABSTAIN` 是合法 autonomy outcome，但不是 performance success。

P3 — AP-2M 成立后运行 AP-3 H0 autonomous bootstrap

Setup。 只提供 shell-only H0 和 AP-3 内部 fresh H0 Worker 产生的 run-local artifact、trace、optimize diagnostic、score、runtime 与 cost；禁止使用 R3/AP-1 candidate、历史高分 artifact、

人工 repair prompt 和 expert root-cause summary。复用 AP-2M 的两轮协议与一个 intermediate probe。

Gates。

- `bootstrap_loop_feasible`：H0 evidence 导致 self-selected experiment 与 feedback-grounded second decision；
- `component_activated`：新 component 实际影响 Worker execution；
- `bootstrap_helpful`：final score 高于 fresh H0，或 predicted runtime fault 修复且无 property regression；
- `binary_helpful`：final independent T26 为 17/17、reward 1。

P4 — 只有 AP-3 positive 后才扩展稳定性与 breadth

按以下顺序扩展：

1. 对 AP-3 positive lineage 做一次 fresh Evolver repeat；
2. 选择一个 failure mechanism 明确不同的第二个 QuantCodeEval task；
3. 再运行一个 QFBench canary，验证同一自主实验接口能否在另一种 artifact contract 下工作；
4. 最后才实现渐进式、异步、成本感知 scheduler，并在冻结 candidate 上运行较大 test set。

最终判断 / Current Verdict

过去一周已经获得了机制论文所需的一条清晰正向链路：系统从合法 `ABSTAIN` 发展到 full-harness ACT、runtime-history refinement、quant-specific component activation、repeated 16/17 property repair，最终出现一次 fresh 17/17 binary success。负结果也直接推动了机制设计：T18 否认无效 boundary hypothesis，T24 暴露 hook reachability 与 component interaction，R5 证明 static semantic checks 不足以保证 runtime stability。

现在不应继续把主要预算投入人工枚举更多 failure classes，也不应提前建设大规模 scheduler。最小且决定性的下一步是 AP-2M：让 Evolver 自己选 probe、看到结果并更新 candidate。AP-2M 成立后，AP-3 才能回答最终的工程问题——系统是否能够从 shell-only H0 自主进化出有二元收益的 quant harness。